# Primeiro Trabalho de Reconhecimento de Padrões

Jakson da Rocha Almeida

27 de abril de 2026

**Organização do documento.** O trabalho é resolvido em duas partes. A Parte I (Questões 1 a 7) usa a configuração original do enunciado: $\mu_1 = (0,0)^\top$, $\mu_2 = (3,3)^\top$ e $\Sigma = I$. A Parte II (Questão 8) refaz cada uma das questões anteriores para $\mu_2 = (2,0)^\top$ e $\Sigma = \left[\begin{smallmatrix} 1 & 0{,}6 \\ 0{,}6 & 1 \end{smallmatrix}\right]$. As sementes para os sorteios das Questões 2 e 4 foram obtidas de uma semente-mestre `MASTER_SEED` = 2026 via duas chamadas sucessivas de `numpy.random.default_rng(2026).integers(0,501)`, produzindo `SEED_Q2` = 426 e `SEED_Q4` = 89. As mesmas sementes são reutilizadas na Parte II para permitir comparação direta entre as duas configurações.

---

**Parte I — Configuração original**

$\mu_1 = (0,0)^\top,\ \mu_2 = (3,3)^\top,\ \Sigma = I$

---

## Questão 1 — Função discriminante de Bayes

**Enunciado.** Obter a função discriminante baseada na regra de Bayes para um problema de classificação com duas classes equiprováveis dadas por

$$C_1 :\ \mathcal{N}(\mu_1, \Sigma), \qquad C_2 :\ \mathcal{N}(\mu_2, \Sigma), \qquad P(C_1) = P(C_2) = \tfrac{1}{2}.$$

**Solução.** A regra de Bayes escolhe a classe que maximiza a probabilidade a posteriori. Como ln é crescente, podemos comparar

$$g_i(\mathbf{x}) = \ln p(\mathbf{x} \mid C_i) + \ln P(C_i).$$

Para Gaussianas em dimensão $d$,

$$g_i(\mathbf{x}) = -\tfrac{1}{2}(\mathbf{x} - \mu_i)^\top \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \tfrac{d}{2}\ln(2\pi) - \tfrac{1}{2}\ln|\Sigma_i| + \ln P(C_i).$$

Como $P(C_1) = P(C_2)$ e $\Sigma_1 = \Sigma_2 = I$, todos os termos constantes em $i$ se cancelam na comparação. Resta $-\frac{1}{2}\|\mathbf{x} - \mu_i\|^2$; expandindo o quadrado, o termo $-\frac{1}{2}\mathbf{x}^\top\mathbf{x}$ também é comum, de modo que basta comparar

$$g_i(\mathbf{x}) = \mu_i^\top \mathbf{x} - \tfrac{1}{2}\mu_i^\top \mu_i.$$

Substituindo $\mu_1 = \mathbf{0}$ e $\mu_2 = (3,3)^\top$, $g_1(\mathbf{x}) = 0$ e $g_2(\mathbf{x}) = 3x_1 + 3x_2 - 9$. A fronteira ocorre quando $g_1 = g_2$, isto é, $3x_1 + 3x_2 - 9 = 0 \Leftrightarrow x_1 + x_2 = 3$. A função discriminante binária é

$$h(\mathbf{x}) = 3x_1 + 3x_2 - 9, \qquad \begin{cases} h(\mathbf{x}) < 0 \Rightarrow \mathbf{x} \in C_1, \\ h(\mathbf{x}) \geq 0 \Rightarrow \mathbf{x} \in C_2. \end{cases}$$

**Interpretação geométrica.** A reta $x_1+x_2=3$ tem normal $(1,1)^\top$, paralela a $\mu_2-\mu_1=(3,3)^\top$, e passa pelo ponto médio $(\mu_1+\mu_2)/2=(1{,}5,1{,}5)^\top$. É a mediatriz dos centros, como esperado para covariâncias iguais e isotrópicas.

# Questão 2 — Geração do conjunto de treinamento

**Enunciado.** Sortear um inteiro entre 0 e 500 como semente, gerar 1000 amostras de cada classe e plotá-las junto com a superfície de separação da Questão 1. Comentar sobre a distribuição das classes no espaço e sobre a forma da superfície.

**Solução.** Da semente-mestre 2026 sorteou-se `SEED_Q2` $=426$ e geraram-se 1000 amostras por classe. A Figura 1 mostra os pontos ($C_1$ em `r+`, $C_2$ em `b.`) e a fronteira da Questão 1 em verde. As médias amostrais são $\hat{\mu}_1\approx(-0{,}0007,\ 0{,}0363)^\top$ e $\hat{\mu}_2\approx(2{,}9797,\ 3{,}0360)^\top$, próximas de $\mu_1$ e $\mu_2$.

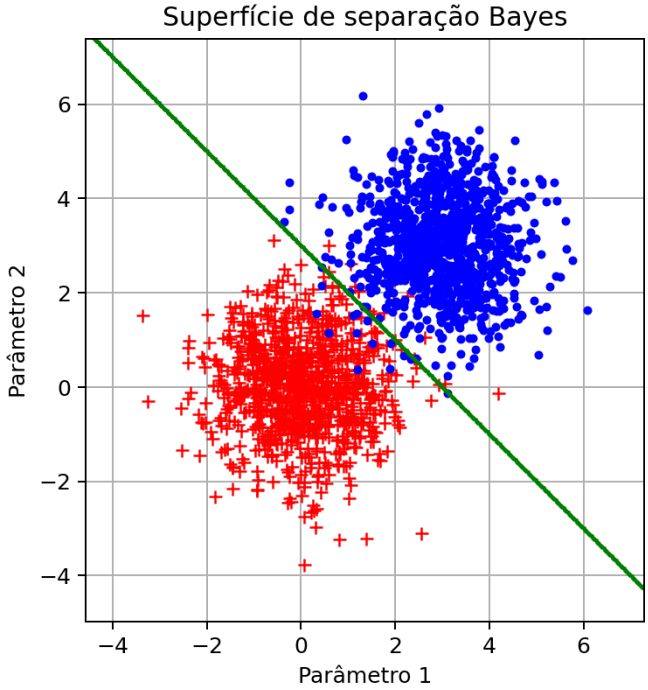


Figura 1: Questão 2: 1000 amostras por classe (`SEED` $=426$) com a superfície ótima de Bayes em verde.

**Comentário.** As isodensidades de cada classe são círculos ($\Sigma=I$); os centros estão separados por $\|\mu_2-\mu_1\|=\sqrt{18}\approx 4{,}24$, isto é, mais de quatro desvios padrão. As núvens praticamente não se sobrepõem, exceto em uma faixa estreita ao longo da fronteira. A superfície de separação é linear (mediatriz dos centros), exatamente como predito pela Questão 1 para covariâncias iguais.

# Questão 3 — Probabilidade de erro teórica e empírica

**Enunciado.** Calcular a probabilidade de erro teórica (através das densidades a posteriori) e estimá-la pelo conjunto de dados gerado na Questão 2.

**Erro teórico.** A regra linear $h(\mathbf{x}) = w^\top \mathbf{x} + b$, com $w = \mu_2 - \mu_1$ e $b = -\frac{1}{2}(\mu_2^\top \mu_2 - \mu_1^\top \mu_1)$, projeta o problema em uma dimensão. Sob $C_i$, $h$ é Gaussiana com média $w^\top \mu_i + b$ e variância $w^\top \Sigma w$. Definindo a distância de Mahalanobis $\delta = \sqrt{(\mu_2 - \mu_1)^\top \Sigma^{-1} (\mu_2 - \mu_1)}$, mostra-se que para priors iguais

$$P_e^{\text{Bayes}} = \Phi\big(-\tfrac{\delta}{2}\big).$$

Para a configuração original, $\delta = \sqrt{18}$ e

$$P_e^{\text{Bayes}} = \Phi\big(-\sqrt{18}/2\big) = \Phi(-2{,}121) \approx 0{,}0169.$$

**Erro empírico.** Aplicando $h(\mathbf{x}) = 3x_1 + 3x_2 - 9$ aos 2000 pontos da Questão 2, obteve-se taxa de erro 0,0155 (31 classificações incorretas).

**Comentário.** O valor empírico (0,0155) está a menos de meio desvio padrão do teórico (0,0169); o desvio padrão amostral é $\sqrt{p(1-p)/n} \approx 0{,}003$ para $n = 2000$. A concordância confirma a derivação da Questão 1.

# Questão 4 — Geração do conjunto de teste

**Enunciado.** Sortear um novo inteiro entre 0 e 500 e gerar 1000 amostras de cada classe para teste.

**Solução.** A segunda chamada de `integers(0,501)` produziu `SEED_Q4` $= 89$, com a qual se geraram 1000 amostras por classe. Esse conjunto é usado nas Questões 5–7. Como referência, o classificador ótimo de Bayes da Questão 3 atinge 0,0120 neste conjunto de teste.

# Questão 5 — Classificador Euclidiano

**Enunciado.** Projetar um classificador baseado na distância Euclidiana às médias das classes (estimadas no conjunto de treinamento). Achar a função discriminante teórica para esse caso e a probabilidade de erro teórica; estimar a probabilidade de erro pelo conjunto de teste.

**Função discriminante teórica.** Decidir pela média mais próxima equivale a maximizar $-\frac{1}{2}\|\mathbf{x} - \mu_i\|^2$. Expandindo e descartando o termo comum $-\frac{1}{2}\mathbf{x}^\top \mathbf{x}$,

$$h_{\text{Euc}}(\mathbf{x}) = (\mu_2 - \mu_1)^\top \mathbf{x} - \tfrac{1}{2}\big(\mu_2^\top \mu_2 - \mu_1^\top \mu_1\big).$$

Para $\mu_1 = \mathbf{0}$ e $\mu_2 = (3,3)^\top$, isto dá $h_{\text{Euc}}(\mathbf{x}) = 3x_1 + 3x_2 - 9$, *coincidente com a regra de Bayes*, pois $\Sigma = I$.

**Erro teórico.** Como a regra teórica do Euclidiano coincide com a de Bayes nesta configuração,

$$P_e^{\text{Euc, teórico}} = \Phi(-\sqrt{18}/2) \approx 0{,}0169.$$

**Versão empírica.** Substituindo $\mu_i$ pelas médias amostrais $\hat{\mu}_i$ obtidas no treino,

$$\hat{h}_{\text{Euc}}(\mathbf{x}) \approx 2{,}9803\, x_1 + 2{,}9997\, x_2 - 9{,}0472.$$

Avaliando-a no conjunto de teste, o erro foi 0,0125.

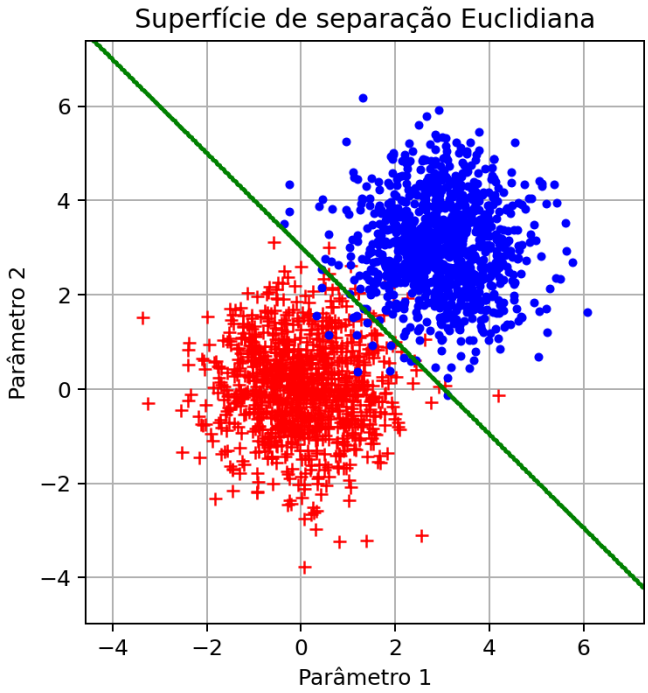


Figura 2: Questão 5: classificador Euclidiano com médias amostrais sobre o conjunto de treino.

**Comentário.** Como $\Sigma = I$, a regra teórica do Euclidiano é igual à de Bayes (mesma fronteira, mesmo erro 0,0169). A versão empírica difere apenas pela estimação das médias com 1000 pontos: o vetor normal (2,98, 3,00) é quase igual a $(3, 3)$, e o erro de teste (0,0125) coincide essencialmente com o de Bayes (0,0120).

# Questão 6 — Bayes ingênuo não paramétrico

**Enunciado.** Projetar um classificador de Bayes ingênuo estimando as densidades de probabilidade das classes de forma não paramétrica, sobre o conjunto de treinamento. Achar graficamente a função discriminante e estimar o erro pelo conjunto de teste.

**Modelo.** O classificador ingênuo assume independência das componentes,

$$p(\mathbf{x} \mid C_i) = \prod_{j=1}^{d} p_j(x_j \mid C_i),$$

e cada marginal $p_j(\cdot \mid C_i)$ foi estimada por KDE Gaussiana (`scipy.stats.gaussian_kde`) com banda de Scott. A regra usa o log-posteriori $g_i(\mathbf{x}) = \ln P(C_i) + \sum_j \ln p_j(x_j \mid C_i)$, e a fronteira é o conjunto $\{\mathbf{x} : g_2(\mathbf{x}) = g_1(\mathbf{x})\}$.

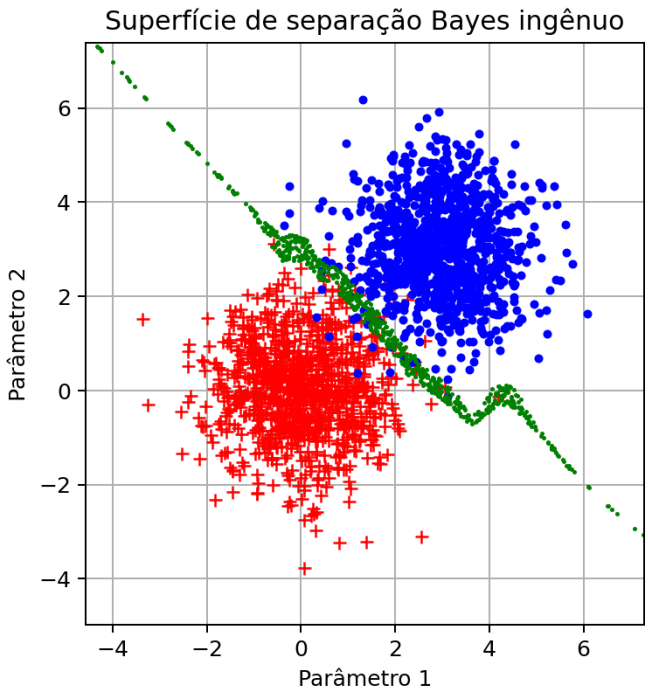


Figura 3: Questão 6: superfície de separação do Bayes ingênuo não paramétrico (KDE marginal).

**Erro de teste.** 0,0155.

**Comentário.** Aqui $\Sigma = I$ é diagonal, logo a hipótese de independência das componentes é *exata*; o ingênuo recupera o classificador ótimo a menos do ruído da estimação KDE. O erro 0,0155 fica entre o de Bayes (0,0120) e o do $k$-NN $k = 5$, refletindo essa pequena perda.

# Questão 7 — $k$-NN

**Enunciado.** Projetar um classificador $k$-NN usando todos os vetores do treino, para $k \in \{1, 5, 11\}$. Achar graficamente a função discriminante para cada caso e estimar o erro pelo conjunto de teste.

**Solução.** Usou-se `KNeighborsClassifier` do scikit-learn com métrica Euclidiana e voto majoritário. As fronteiras estão na Figura 4.

**Erros e matrizes de confusão.** As matrizes seguem a convenção

$$\begin{bmatrix} \#(C_1 \to C_1) & \#(C_1 \to C_2) \\ \#(C_2 \to C_1) & \#(C_2 \to C_2) \end{bmatrix}.$$

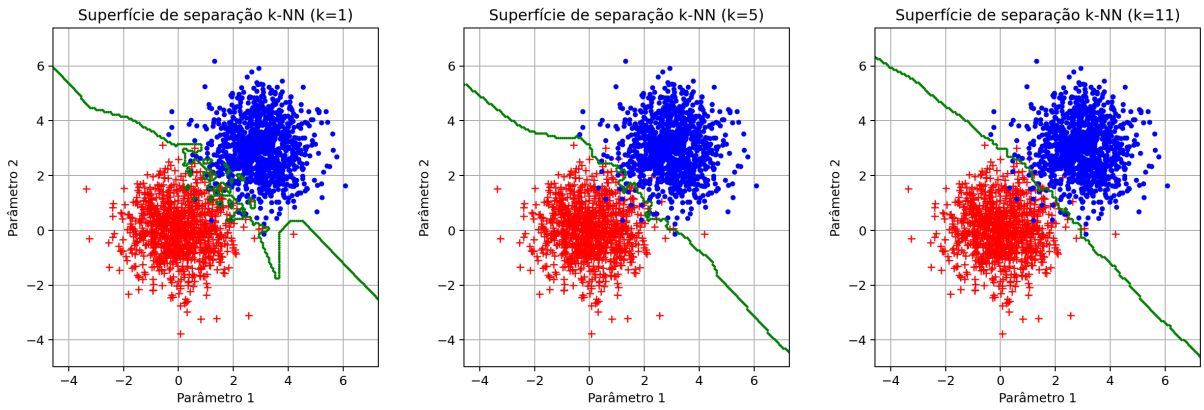


$k = 1$ $k = 5$ $k = 11$

Figura 4: Questão 7: fronteiras de decisão do $k$-NN para $k \in \{1, 5, 11\}$, configuração original.

| $k$ | Erro de teste | Matriz de confusão |
|---|---|---|
| 1 | 0,0245 | $\begin{bmatrix} 980 & 20 \\ 29 & 971 \end{bmatrix}$ |
| 5 | 0,0170 | $\begin{bmatrix} 985 & 15 \\ 19 & 981 \end{bmatrix}$ |
| 11 | 0,0145 | $\begin{bmatrix} 987 & 13 \\ 16 & 984 \end{bmatrix}$ |

**Comentário.** Para $k = 1$, a fronteira é irregular e o classificador tem alta variância, com erro de teste 0,0245. À medida que $k$ aumenta, a média local suaviza a fronteira: $k = 11$ atinge 0,0145, abaixo do erro empírico de Bayes (0,0120 é limite assintótico teórico 0,0169). É flutuação amostral favorável; pelo limite de Cover–Hart, $P_{k\text{-NN}} \leq 2P_e^{\text{Bayes}}$ para $k$ fixo.

# Resumo da Parte I

| Classificador | Erro teórico | Erro de teste |
|---|---|---|
| Bayes ótimo | 0,0169 | 0,0120 |
| Euclidiano teórico ($\mu$ verdadeiros) | 0,0169 | — |
| Euclidiano empírico (médias estimadas) | 0,0170 | 0,0125 |
| Bayes ingênuo KDE | — | 0,0155 |
| $k$-NN, $k = 1$ | — | 0,0245 |
| $k$-NN, $k = 5$ | — | 0,0170 |
| $k$-NN, $k = 11$ | — | 0,0145 |

Tabela 1: Configuração original ($\mu_1 = (0, 0)^\top$, $\mu_2 = (3, 3)^\top$, $\Sigma = I$): probabilidades de erro.

## Parte II — Questão 8 (nova configuração)

$\mu_1 = (0, 0)^\top$, $\mu_2 = (2, 0)^\top$, $\Sigma = \begin{bmatrix} 1 & 0{,}6 \\ 0{,}6 & 1 \end{bmatrix}$

# Questão 8 — Nova configuração das classes

**Enunciado.** Mudar as classes para

$$C_1 : \mathcal{N}\big(\mu_1 = \tbinom{0}{0}, \Sigma\big), \qquad C_2 : \mathcal{N}\big(\mu_2 = \tbinom{2}{0}, \Sigma\big), \qquad \Sigma = \begin{bmatrix} 1 & 0{,}6 \\ 0{,}6 & 1 \end{bmatrix},$$

e refazer todas as questões anteriores.

As mesmas sementes (`SEED_Q2` $= 426$, `SEED_Q4` $= 89$) e o mesmo $n = 1000$ são usados, alterando apenas $\mu_2$ e $\Sigma$. Cada subseção a seguir refaz uma das questões anteriores.

## Refazendo a Questão 1: função discriminante

A simplificação da Questão 1 ainda vale para $-\frac{1}{2}\mathbf{x}^\top\Sigma^{-1}\mathbf{x}$ (termo comum, pois $\Sigma$ é o mesmo nas duas classes), o que ainda leva a uma regra linear:

$$h(\mathbf{x}) = (\mu_2 - \mu_1)^\top\Sigma^{-1}\mathbf{x} - \tfrac{1}{2}\big(\mu_2^\top\Sigma^{-1}\mu_2 - \mu_1^\top\Sigma^{-1}\mu_1\big).$$

Calculando $\Sigma^{-1}$ com $\det\Sigma = 1 - 0{,}36 = 0{,}64$,

$$\Sigma^{-1} = \frac{1}{0{,}64}\begin{bmatrix} 1 & -0{,}6 \\ -0{,}6 & 1 \end{bmatrix} = \begin{bmatrix} 1{,}5625 & -0{,}9375 \\ -0{,}9375 & 1{,}5625 \end{bmatrix}.$$

Como $\mu_1 = \mathbf{0}$, $\Sigma^{-1}(\mu_2 - \mu_1) = (3{,}125, -1{,}875)^\top$ e $\frac{1}{2}\mu_2^\top\Sigma^{-1}\mu_2 = \frac{1}{2}(2)(3{,}125) = 3{,}125$, de onde

$$h(\mathbf{x}) = 3{,}125\,x_1 - 1{,}875\,x_2 - 3{,}125, \qquad \begin{cases} h(\mathbf{x}) < 0 \Rightarrow C_1, \\ h(\mathbf{x}) \geq 0 \Rightarrow C_2. \end{cases}$$

A fronteira ainda é uma reta, porém é ortogonal a $\Sigma^{-1}(\mu_2 - \mu_1)$ *na geometria de Mahalanobis* — e não mais ao vetor $\mu_2 - \mu_1$ no plano Euclidiano.

## Refazendo a Questão 2: geração de dados

Com `SEED_Q2` $= 426$ e a nova distribuição, geraram-se 1000 amostras por classe. As médias amostrais são $\hat{\mu}_1 \approx (-0{,}0156,\ 0{,}0169)^\top$ e $\hat{\mu}_2 \approx (2{,}0021,\ 0{,}0343)^\top$.

**Comentário.** As isodensidades agora são elipses inclinadas (correlação 0,6) e os centros distam apenas $\|\mu_2 - \mu_1\| = 2$ no plano Euclidiano. Visualmente, há sobreposição substancial entre as classes. A superfície tem inclinação negativa porque o vetor normal $\Sigma^{-1}(\mu_2 - \mu_1) = (3{,}125, -1{,}875)^\top$ tem componente $x_2$ negativa: a correlação positiva entre as variáveis "inclina" a fronteira na direção oposta à do gradiente de uma simples diferença de médias.

## Refazendo a Questão 3: erro de Bayes

Com a mesma fórmula geral $P_e^{\text{Bayes}} = \Phi(-\delta/2)$ e

$$\delta^2 = (\mu_2 - \mu_1)^\top\Sigma^{-1}(\mu_2 - \mu_1) = (2, 0)\begin{pmatrix} 3{,}125 \\ -1{,}875 \end{pmatrix} = 6{,}25, \qquad \delta = 2{,}5,$$

$$P_e^{\text{Bayes}} = \Phi(-1{,}25) \approx 0{,}1056.$$

O erro empírico nos dados da Questão 2 desta parte foi 0,1060.

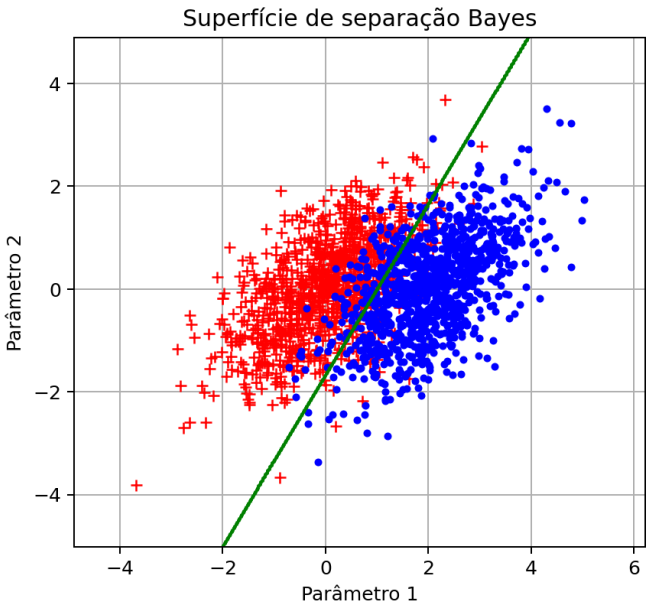


Figura 5: Q8/Q2: 1000 amostras por classe e superfície ótima $h(\mathbf{x}) = 3{,}125\,x_1 - 1{,}875\,x_2 - 3{,}125$.

**Comentário.** O erro é $\sim 6$ vezes maior do que na configuração original (0,1056 vs. 0,0169): as classes ficaram mais próximas e a correlação reduz a separabilidade *efetiva* (Mahalanobis 2,5 vs. Euclidiana $\sqrt{18} \approx 4{,}24$ do problema original).

## Refazendo a Questão 4: conjunto de teste

Com `SEED_Q4` = 89 e a nova distribuição, gerou-se um conjunto de teste com 1000 amostras por classe. O erro de teste do Bayes ótimo é 0,0990.

## Refazendo a Questão 5: classificador Euclidiano

**Função teórica.** A regra Euclidiana com médias verdadeiras *ignora* $\Sigma$:

$$h_{\text{Euc}}(\mathbf{x}) = (\mu_2 - \mu_1)^\top \mathbf{x} - \tfrac{1}{2}(\mu_2^\top \mu_2 - \mu_1^\top \mu_1) = 2x_1 - 2.$$

A fronteira é a reta vertical $x_1 = 1$.

**Erro teórico.** Sob $C_i$, $h$ é Gaussiana com média $w^\top \mu_i + b$ e variância $w^\top \Sigma w$. Aqui $w = (2, 0)^\top$ e $b = -2$, portanto $w^\top \Sigma w = 4$, $s = 2$, $m_1 = -2$ e $m_2 = 2$. Logo

$$P_e^{\text{Euc, teórico}} = \tfrac{1}{2}\left[1 - \Phi(1)\right] + \tfrac{1}{2}\,\Phi(-1) = \Phi(-1) \approx 0{,}1587.$$

*O Euclidiano deixa de ser ótimo*: o gap $0{,}1587 - 0{,}1056 = 0{,}0531$ é o preço de ignorar a correlação.

**Versão empírica.** Com as médias amostrais, $\hat{h}_{\text{Euc}}(\mathbf{x}) \approx 2{,}0177\,x_1 + 0{,}0174\,x_2 - 2{,}0045$. Erro no teste: 0,1645.

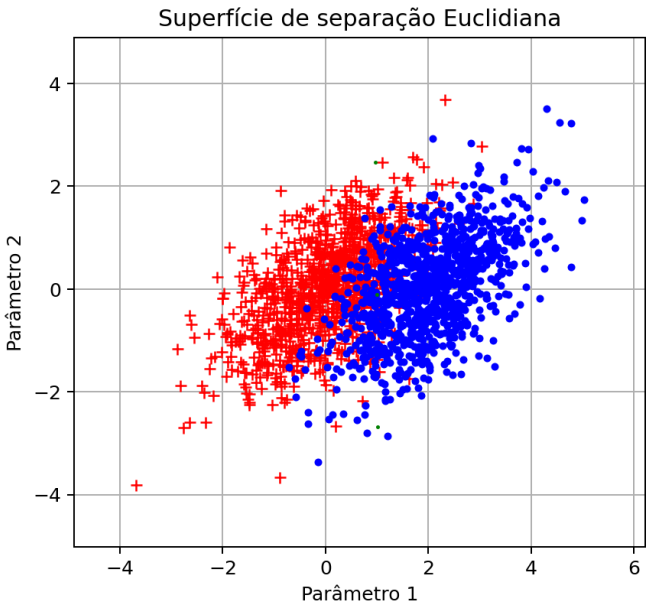


Figura 6: Q8/Q5: classificador Euclidiano empírico (médias amostrais) sobre o conjunto de treino da nova configuração.

**Comentário.** A versão empírica fica ligeiramente pior que a teórica (erro 0,1645 vs. 0,1587) por causa da estimação das médias. O fato qualitativo é que ambas *deixam* cerca de 5 pontos percentuais sobre a mesa em relação ao ótimo de Bayes (0,1056).

## Refazendo a Questão 6: Bayes ingênuo não paramétrico

Mesmo modelo da Questão 6: KDE Gaussiana marginal por classe e log-posterior produto. Erro de teste: 0,1620.

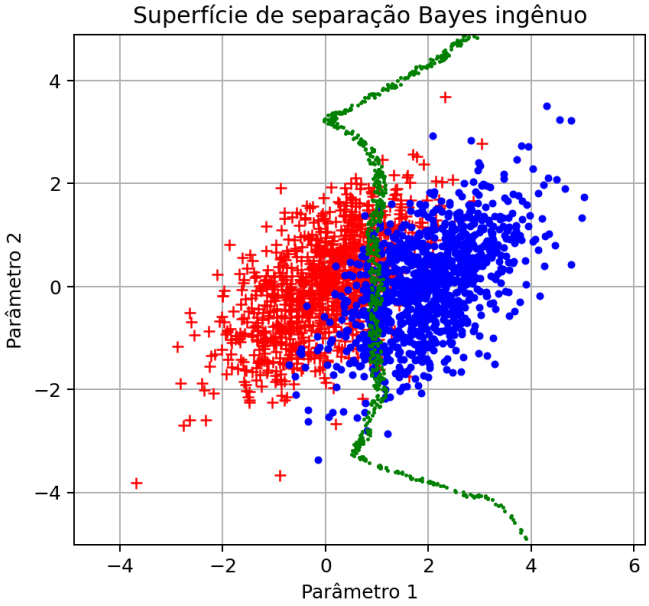


Figura 7: Q8/Q6: superfície do Bayes ingênuo KDE para a nova configuração.

**Comentário.** A hipótese de independência das marginais é violada (correlação 0,6 entre $x_1$ e $x_2$). Por isso o ingênuo desempenha mal, na mesma faixa do Euclidiano (0,1620 vs. 0,1645) e bem acima de Bayes (0,0990 no teste).

## Refazendo a Questão 7: $k$-NN

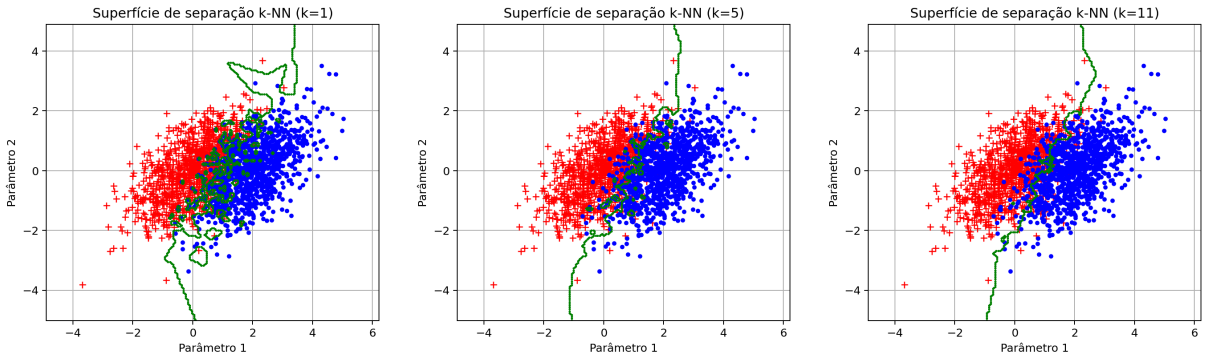


$k = 1$ $k = 5$ $k = 11$

Figura 8: Q8/Q7: fronteiras do $k$-NN para $k \in \{1, 5, 11\}$ na nova configuração.

| $k$ | Erro de teste | Matriz de confusão |
|---|---|---|
| 1 | 0,1430 | $\begin{bmatrix} 856 & 144 \\ 142 & 858 \end{bmatrix}$ |
| 5 | 0,1060 | $\begin{bmatrix} 888 & 112 \\ 100 & 900 \end{bmatrix}$ |
| 11 | 0,0960 | $\begin{bmatrix} 899 & 101 \\ 91 & 909 \end{bmatrix}$ |

**Comentário.** O $k$-NN é não paramétrico e, por isso, *não* sofre da hipótese de independência que afeta o ingênuo, nem ignora $\Sigma$ como o Euclidiano. Para $k = 11$ obteve-se 0,0960, ligeiramente abaixo do erro de Bayes teórico (0,1056); novamente é flutuação amostral favorável, pois o limite assintótico do $k$-NN com $k$ fixo é $\leq 2P_e^{\text{Bayes}}$.

### Resumo da Questão 8

| Classificador | Erro teórico | Erro de teste |
|---|---|---|
| Bayes ótimo | 0,1056 | 0,0990 |
| Euclidiano teórico ($\mu$ verdadeiros) | 0,1587 | — |
| Euclidiano empírico (médias estimadas) | 0,1599 | 0,1645 |
| Bayes ingênuo KDE | — | 0,1620 |
| $k$-NN, $k = 1$ | — | 0,1430 |
| $k$-NN, $k = 5$ | — | 0,1060 |
| $k$-NN, $k = 11$ | — | 0,0960 |

Tabela 2: Questão 8 (nova configuração): probabilidades de erro.

## Síntese final

Comparando as duas configurações:

- Com $\Sigma = I$ e centros bem separados (Parte I), todos os classificadores ficam próximos do ótimo de Bayes ($\sim 1{,}5\%$), inclusive o Euclidiano e o ingênuo, porque ambas as suas hipóteses de simplificação (covariância identidade e independência marginal) são satisfeitas.
- Com $\Sigma$ correlacionado e centros mais próximos (Parte II), Bayes (que usa $\Sigma^{-1}$) atinge $\sim 10{,}6\%$ teórico, enquanto Euclidiano e ingênuo, que ignoram a correlação, ficam acima de 15%. É o preço de modelos com hipóteses incorretas.
- O $k$-NN, não paramétrico, recupera a estrutura local em ambas as configurações; com $k = 11$ atinge desempenho comparável ao de Bayes nos dois cenários.