

Segundo Trabalho de Reconhecimento de Padrões

Jakson da Rocha Almeida

10 de maio de 2026

Introdução

Este relatório documenta a implementação das questões do segundo trabalho, realizada em Python com `numpy`, `matplotlib` e `scikit-learn`. Os dados seguem duas classes Gaussianas bidimensionais com a mesma matriz de covariância $\Sigma = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}$, médias $\mu_1 = (0, 0)^\top$ e $\mu_2 = (2, 0)^\top$, e probabilidades à priori iguais.

Para tornar os sorteios reproduzíveis (sem contrariar o enunciado, que pede inteiros em $[0, 500]$ como raízes), utilizamos sementes mestras fixas no notebook: `MASTER_SEED=2027` para obter a semente do treino da Questão 2 (316) e `MASTER_Q34=2028` para a “raiz” das Questões 3–4, correspondendo ao inteiro 283 usado na geração do teste. As figuras são gravadas na pasta `documents/trabalho2/figures/`.

Questão 1 — Definição das classes

Duas classes C_1 e C_2 , cada uma $\mathcal{N}(\mu_i, \Sigma)$ com Σ compartilhada, conforme o enunciado.

Questão 2 — Treino e fronteira de Bayes

Sorteou-se o inteiro $316 \in [0, 500]$ e geraram-se $n = 1000$ amostras por classe. Superpõe-se a **fronteira ótima de Bayes** (linear neste modelo), igual à derivada no primeiro trabalho para esta mesma configuração:

$$h(\mathbf{x}) = 3,125 x_1 - 1,875 x_2 - 3,125 = 0.$$

Questões 3 e 4 — Conjunto de teste

O inteiro sorteado em $[0, 500]$ para a raiz do teste foi 283. Geraram-se novamente 1000 amostras por classe, independentes do treino, totalizando 2000 pontos de teste etiquetados ($y \in \{0, 1\}$ com $C_1 \rightarrow 0$, $C_2 \rightarrow 1$).

Erro teórico de Bayes (referência para as comparações)

Com covariância comum e priors iguais, a regra de Bayes é linear e a probabilidade de erro vale $P_e^{(\text{Bayes})} = \Phi(-d_M/2)$, onde $d_M = \sqrt{(\mu_2 - \mu_1)^\top \Sigma^{-1} (\mu_2 - \mu_1)}$. Aqui $d_M = 2,5$, logo $P_e^{(\text{Bayes})} \approx 0,1056$ aproximadamente 10,6%.




Figura 1: Questão 2: treino (1000 pontos por classe) e fronteira de Bayes.

Questão 5 — Perceptron (treino completo)

Treinou-se um perceptron linear (`sklearn.linear_model.Perceptron`) com todo o conjunto de treino, critérios de parada via `max_iter` e `tol`, e avaliou-se no teste.

Resultado. Erro empírico estimado $\hat{P}_e \approx 0,1655$. Esperava-se valor **superior** ao de Bayes: o perceptron minimiza erros por atualizações e não incorpora explicitamente Σ^{-1} nem maximiza verossimilhança das Gaussianas.

Questões 6 e 7 — Perceptron com 50+50 amostras

Do treino completo, extraíram-se dois blocos disjuntos de 50 pontos por classe (permutações fixas com `rng_sub = np.random.default_rng(3030)`).

Resultados.

- Questão 6 (primeiro bloco): $\hat{P}_e \approx 0,3565$.
- Questão 7 (segundo bloco): $\hat{P}_e \approx 0,1080$.

A dispersão entre os dois blocos é grande: com poucos exemplos e overlap das classes, a reta aprendida depende fortemente do subconjunto.

Questões 8 a 10 — Mínimos quadrados (pseudoinversa)

Implementou-se o classificador linear por MQ com matriz aumentada $\tilde{\mathbf{X}} = [\mathbf{1} \mid \mathbf{X}]$, alvos ± 1 e solução $\hat{\boldsymbol{\theta}} = \tilde{\mathbf{X}}^+ \mathbf{y}$ (`numpy.linalg.pinv`), classe prevista pela polaridade de $\tilde{\mathbf{x}}^\top \hat{\boldsymbol{\theta}}$.

Questão 5 — Perceptron: teste e fronteiras




Figura 2: Questão 5: perceptron no conjunto de teste e referência Bayes (verde).

Resultados.

- Questão 8 (treino completo): $\hat{\theta} \approx [-0,599, 0,612, -0,396]^\top$ (formato $[b, w_1, w_2]$), $\hat{P}_e \approx 0,1035$.
- Questão 9 (mesmo 50+50 da Q6): $\hat{P}_e \approx 0,1110$.
- Questão 10 (mesmo 50+50 da Q7): $\hat{P}_e \approx 0,1030$.

Questões 11 a 13 — SVM linear com margem suave

Usou-se `SVC(kernel="linear", C=1.0)`. No treino completo há muitos vetores de suporte porque as classes se sobrepõem na distribuição geradora.

Resultados.

- Questão 11: 525 vetores de suporte no total, $\hat{P}_e \approx 0,1005$.

Questão 6 — Perceptron (50+50, bloco 1) no teste




Figura 3: Questão 6: perceptron com 50+50 (bloco 1).

- Questão 12 (bloco 1): 32 vetores de suporte, $\hat{P}_e \approx 0,1140$.
- Questão 13 (bloco 2): 33 vetores de suporte, $\hat{P}_e \approx 0,1050$.

Questão 7 — Perceptron (50+50, bloco 2) no teste




Figura 4: Questão 7: perceptron com 50+50 (bloco 2).

Questão 8 — LS (pseudoinversa): treino completo no teste





Figura 5: Questão 8: MQ com treino completo.

Questão 9 — LS (50+50, bloco 1) no teste



Questão 10 — LS (50+50, bloco 2) no teste




Figura 6: Questões 9 e 10: MQ com blocos 50+50.

Questão 11 — SVM linear ($C=1$): treino completo no teste





Figura 7: Questão 11: SVM linear ($C = 1$), treino completo.

Questão 12 — SVM linear (50+50, bloco 1) no teste



Questão 13 — SVM linear (50+50, bloco 2) no teste




Figura 8: Questões 12 e 13: SVM nos dois blocos 50+50.

Quadro-resumo — probabilidade de erro no teste

Questão	Método	Tamanho do treino	$\hat{P}_e$
—	Bayes (teórico)	—	$\approx 0,1056$
5	Perceptron	1000+1000	0,1655
6	Perceptron	50+50 (bloco 1)	0,3565
7	Perceptron	50+50 (bloco 2)	0,1080
8	MQ (pseudoinversa)	1000+1000	0,1035
9	MQ	50+50 (bloco 1)	0,1110
10	MQ	50+50 (bloco 2)	0,1030
11	SVM linear ($C=1$)	1000+1000	0,1005
12	SVM linear	50+50 (bloco 1)	0,1140
13	SVM linear	50+50 (bloco 2)	0,1050

Tabela 1: Erros empíricos no mesmo conjunto de teste (2000 amostras).

Questão 14 — Síntese e comparação com Bayes

O limiar ótimo de Bayes ($\approx 10,6\%$ de erro) serve como referência inferior para este problema gerador.

Com treino completo, tanto **mínimos quadrados** (10,35%) quanto o **SVM linear** com $C=1$ (10,05%) aproximaram-se desse valor, o que é esperado: a fronteira de Bayes é linear e ambos os métodos produzem separadores lineares adequados a dados quase linearmente separáveis em média.

O **perceptron** no treino completo ficou substancialmente acima (16,55%), consistente com o facto de o algoritmo não estimar directamente o classificador likelihood-ratio ótimo para Gaussianas.

Com apenas 50+50 exemplos, todos os métodos oscilam em torno do valor de Bayes, mas o **perceptron** mostrou o comportamento mais extremo (de $\approx 35,7\%$ a $\approx 10,8\%$ entre os dois blocos), evidenciando forte sensibilidade ao ruído amostral. **MQ** e **SVM** mantiveram diferenças menores entre blocos ($\approx 0,8$ p.p. e $\approx 0,9$ p.p., respectivamente), mais coerentes com modelos que estabilizam o hiperplano (solução fechada do MQ; maximização de margem suavizada no SVM).

Questão 15 — Polarização (viés) e variância entre os três métodos lineares

Neste trabalho não estimámos viés e variância por Monte Carlo com muitas repetições; interpretamos os conceitos de forma **qualitativa e empírica** com base em (i) erro com treino grande e (ii) dispersão entre os dois subconjuntos fixos de 50+50.

- **Variância entre os dois blocos pequenos:** o **perceptron** apresentou claramente a maior dispersão de $\hat{P}_e$. **Mínimos quadrados** e **SVM** tiveram dispersões semelhantes e bem menores.

- **Polarização relativa a Bayes com treino completo:** o perceptron ficou mais afastado do erro teórico de Bayes. O SVM obteve $\hat{P}_e$ mais próximo de $P_e^{(\text{Bayes})}$, seguido de perto pelo MQ.

Assim, **não há um único** dos três que minimize simultaneamente, nos dois critérios observados, polarização e variância: se se privilegia estabilidade entre os dois blocos 50+50, destacam-se **MQ** e **SVM**; se se privilegia proximidade ao Bayes com todo o treino, destaca-se sobretudo o **SVM** neste ensaio.