

Pré-processamento e Avaliação de Classificadores

Augusto Santiago Cerqueira

Introdução

- Conjuntos de dados são formados por objetos que podem representar algo físico ou abstrato
- Nos referimos a esses objetos comumente como padrões ou instâncias e cada objeto é descrito por um conjunto de atributos ou parâmetros, também chamados de atributos de entrada, vetores de parâmetros ou vetores de características
- Cada objeto está associado a uma ocorrência dos dados, enquanto cada parâmetro está associado a uma propriedade do objeto

Caracterização de dados

- Um conjunto de dados pode ser representado formalmente por uma matriz de objetos $X_{n \times l}$ onde n é o número de instâncias e l o número de parâmetros
- O número l define a dimensionalidade do espaço de parâmetros. Cada elemento dessa matriz x_{ij} contém o valor da j -ésima característica para a i -ésima instância
- Os l parâmetros podem ser vistos como um conjunto de eixos ortogonais e as instâncias, como pontos no espaço de l dimensões

Caracterização de dados

Tabela 2.1 Conjunto de dados <code>hospital</code> com seus atributos									
Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Caracterização de dados

- [Repositório de dados da Universidade da Califórnia para aprendizado de máquinas](#)

Caracterização de dados

- Desafios em relação a quantidade de instâncias n e de parâmetros l para o projeto e desempenho de máquinas de aprendizado (ferramentas de IA):
 - Quanto maior o l , maior deverá ser n para viabilizar o projeto e o bom desempenho
 - Quanto maior o l , maior será a variância da máquina e maior será sua complexidade computacional
 - Quanto maior o n , maior a complexidade computacional para projeto
 - Quanto maior a relação n/l , melhor será o projeto da máquina
- **Maldição da Dimensionalidade:** quando o número de parâmetros ou dimensões aumenta, a quantidade de instâncias ou dados necessários para generalizar o modelo de aprendizado de máquina com precisão aumenta exponencialmente

Pré-processamento

- Técnicas de pré-processamento de dados são normalmente utilizadas para melhorar a qualidade dos dados e resolver alguns problemas comumente encontrados em diversas bases de dados
- O pré-processamento é muitas vezes fundamental para o projeto adequado de uma máquina de aprendizado

Pré-processamento: eliminação manual de parâmetros

Tabela 2.1 Conjunto de dados `hospital` com seus atributos

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Pré-processamento: limpeza dos dados

- Conjuntos de dados podem apresentar dados **inconsistentes**, **redundantes** e/ou **incompletos**
- Algumas técnicas conseguem lidar bem com alguns desses problemas, já outras têm dificuldades e/ou não conseguem lidar
- Por outro lado, todas as técnicas de classificação irão se beneficiar de técnicas de pré-processamento de dados que possam eliminar ou melhorar a qualidade dos dados

Limpeza de dados: dados incompletos

- Um dos problemas que pode ser encontrado em conjunto de dados é a ausência de valores para alguns parâmetros de alguns objetos
- Alternativas mais utilizadas para lidar com dados faltantes:
 - Eliminar os objetos com dados faltantes. Proibitivo para o caso de poucas instâncias disponíveis
 - Utilizar algum método ou heurística para o preenchimento automático dos valores dos parâmetros faltantes
- Definição automática de valores pode ser feita de três formas:
 - Estabelecer para o parâmetro um valor que indique para a máquina de aprendizado que o parâmetro possui valor desconhecido
 - Utilizar a média, moda ou mediana dos valores conhecidos para esse atributo
 - Empregar algum estimador que leve em consideração os demais parâmetros do objeto

Limpeza de dados: dados inconsistentes

- Dados inconsistentes são aqueles que possuem dados conflitantes em seus parâmetros
- Algoritmos simples podem ser usados para automaticamente verificar se relacionamentos existentes entre atributos são violados
- Para conjuntos de dados pequenos, a verificação pode ser feita manualmente
- Uma vez identificada, procedimento semelhante ao de dados faltantes pode ser utilizado para substituição do valor do parâmetro inconsistente

Pré-processamento: dados desbalanceados

- O problema de desbalanceamento de dados é muito comum em problemas de classificação
- Em conjuntos de dados reais, o número de objetos varia para as diferentes classes, o que introduz problemas de aprendizado para diferentes técnicas que tendem a representar melhor as classes com número maior de eventos
- Por isso, em geral, busca-se trabalhar com classes balanceadas
- Se tivermos acesso ao processo de geração dos dados, podemos realizar o balanceamento de forma simples
- Em situações em que não temos acesso, temos três principais abordagens para tratar do problema do desbalanceamento:
 - Redefinir o tamanho do conjunto de dados
 - Definir custos diferentes para cada classe
 - Induzir um modelo para uma classe

Dados desbalanceados: abordagens

- Sub amostrar a classe majoritária mantendo a população original da classe minoritária. Pode ser utilizado em caso de grande número de eventos para a classe minoritária. Caso a classe minoritária tenha poucas amostras, é necessário cuidado adicional para a avaliação da performance
- Reamostrar de forma randômica a classe minoritária até atingir número de amostras igual a classe majoritária
- Combinar as duas abordagens
- Em geral, estratégias adequadas para avaliação do desempenho devem ser utilizadas em conjunto com as técnicas de reamostragem

Dados desbalanceados: SMOTE (Synthetic Minority Over-sampling TEchnique)

- A classe minoritária é super amostrada introduzindo exemplos sintéticos para cada amostra da classe minoritária ao longo dos segmentos de reta que unem qualquer/todos os k vizinhos mais próximos da classe minoritária
- Amostras sintéticas são geradas da seguinte forma: pegue a diferença entre o vetor de características (amostra) em questão e seu vizinho mais próximo. Multiplique essa diferença por um número aleatório entre 0 e 1, e adicione-o ao vetor de características em questão. Isso faz com que um ponto aleatório seja selecionado ao longo do segmento de linha entre duas características específicas

Dados desbalanceados: SMOTE

Algorithm *SMOTE*(T , N , k)

Input: Number of minority class samples T ; Amount of SMOTE $N\%$; Number of nearest neighbors k


Output: $(N/100) * T$ synthetic minority class samples

1. *(* If N is less than 100%, randomize the minority class samples as only a random percent of them will be SMOTEd. *)*
2. **if** $N < 100$
3. **then** Randomize the T minority class samples
4. $T = (N/100) * T$
5. $N = 100$
6. **endif**
7. $N = (int)(N/100)$ *(* The amount of SMOTE is assumed to be in integral multiples of 100. *)*
8. k = Number of nearest neighbors
9. $numattrs$ = Number of attributes
10. $Sample[][]$: array for original minority class samples
11. $newindex$: keeps a count of number of synthetic samples generated, initialized to 0
12. $Synthetic[][]$: array for synthetic samples
 (Compute k nearest neighbors for each minority class sample only. *)*
13. **for** $i \leftarrow 1$ **to** T
14. Compute k nearest neighbors for i , and save the indices in the $nnarray$
15. $Populate(N, i, nnarray)$
16. **endfor**


 $Populate(N, i, nnarray)$ *(* Function to generate the synthetic samples. *)*
17. **while** $N \neq 0$
18. Choose a random number between 1 and k , call it nn . This step chooses one of the k nearest neighbors of i .
19. **for** $attr \leftarrow 1$ **to** $numattrs$
20. Compute: $dif = Sample[nnarray[nn]][attr] - Sample[i][attr]$
21. Compute: gap = random number between 0 and 1
22. $Synthetic[newindex][attr] = Sample[i][attr] + gap * dif$
23. **endfor**
24. $newindex++$
25. $N = N - 1$
26. **endwhile**
27. **return** *(* End of Populate. *)*
End of Pseudo-Code.

Dados desbalanceados: Exemplo



dados desbalanceados 10%, 90%



SMOTE k=5



dados balanceados



SMOTE k=20

Limpeza de dados: dados redundantes

- Um conjunto de dados pode conter tanto objetos quanto parâmetros redundantes
- Objetos e parâmetros redundantes em um conjunto de dados atrapalham o projeto de máquinas de aprendizado, por isso é desejável a eliminação das redundâncias
- O processo de seleção de parâmetros pode lidar com o problema de redundância entre parâmetros através da análise de componentes principais (PCA)
- A PCA é uma transformação linear que projeta o conjunto de dados em uma nova base onde não há correlação entre os parâmetros. Além de projetar na nova base, ordena as componentes em relação a sua energia, o que pode ser utilizado como um critério de seleção de parâmetros

Análise de Componentes Principais (PCA)

- Objetivo: Dado um conjunto com m parâmetros $\underline{x} \in R^m$, achar $\underline{y} \in R^l$ onde
$$\underline{y} = A^T \underline{x}$$

para uma matriz $\mathbf{A}$ ortogonal, de forma que os elementos de $\underline{y}$ sejam mutuamente descorrelacionados.

Ou seja, $E[y(i)y(j)] = 0, i \neq j$

Análise de Componentes Principais (PCA)

- Achando $\mathbf{A}$

$$R_y = E[\underline{y}\underline{y}^T] = E[\mathbf{A}^T \underline{x}\underline{x}^T \mathbf{A}] = \mathbf{A}^T R_x \mathbf{A}$$


- Se $\mathbf{A}$ for escolhida com suas colunas $\underline{a}_i$ iguais aos autovetores de R_x , então

$$R_y = \mathbf{A}^T R_x \mathbf{A} = \mathbf{\Lambda}$$

onde $\mathbf{\Lambda}$ é uma matriz diagonal cujos elementos são os respectivos autovalores λ_i

- Observar que essa é uma condição suficiente mas não necessária, o que impõe uma estrutura ortogonal específica para $\mathbf{A}$


Análise de Componentes Principais (PCA)




$\underline{y}$ é uma projeção de $\underline{x}$ em um subespaço formado pelos l principais autovetores. Entretanto, essa pode não ser a melhor solução para o reconhecimento de padrões.

PCA: Exemplo 1

espaço original




espaço transformado PCA




PCA: Exemplo


espaço original



espaço transformado PCA



primeira e segunda PCA



Pré-processamento: normalização

- Em várias situações práticas o valor de cada parâmetro se encontra em diferentes faixas dinâmicas, o que em geral causa problema para o projeto adequado das técnicas de classificação
- A solução é normalizar os dados para que cada parâmetro caia sempre dentro de uma faixa de valores semelhante

$$\hat{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j}$$

onde

$$\bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}$$

$$\sigma_j^2 = \frac{1}{N-1} \sum_{i=1}^N (x_{ij} - \bar{x}_j)^2$$


$$\hat{x}_{ij} = -1 + \frac{x_{ij} - \min_i(x_{ij})}{\max_i(x_{ij}) - \min_i(x_{ij})} * 2$$

$$\hat{x}_{ij} = \frac{x_{ij} - \min_i(x_{ij})}{\max_i(x_{ij}) - \min_i(x_{ij})}$$


- Obs: em alguns casos, as diferenças de escala entre os parâmetros deve ser preservada

Normalização: Exemplo

espaço original




dado normalizado (média e variância)




Normalização: Exemplo

espaço original




dado normalizado (min max)




Normalização: Exemplo

espaço original



dado normalizado (max abs)



Avaliação de Sistemas

- O objetivo é estimar a probabilidade de erro (eficiência) do sistema de classificação projetado

- Técnica de contagem do erro

- Sejam M classes
- Sejam N_i eventos para cada classe ω_i para teste

$$\sum_{i=1}^M N_i = N \quad \text{o número de eventos de teste}$$

- Seja P_i a probabilidade de erro para classe
- Assumindo que o classificador tenha sido projetado por um outro conjunto de dados independente
- Assumindo que os vetores de parâmetros no conjunto de teste sejam independentes, a probabilidade de k_i vetores da classe ω_i serem erroneamente classificados

$$\text{prob}\{k_i \text{ em } \omega_i \text{ sejam erroneamente classificados}\} = \binom{N_i}{k_i} P_i^{k_i} (1 - P_i)^{N_i - k_i}$$

Avaliação de sistemas

- Como as P_i 's não são conhecidas, podemos estimar P_i através da maximização da distribuição binomial anterior. O que resulta em

$$\hat{P}_i = \frac{k_i}{N_i}$$

- Logo, contam-se os eventos errados e divide-se pelo total de eventos de teste pertencente a classe
- Probabilidade total do erro

$$\hat{P} = \sum_{i=1}^M P(\omega_i) \frac{k_i}{N_i}$$

Avaliação de sistemas

- Propriedades estatísticas

- $E[k_i] = N_i P_i$

- Então, $E[\hat{p}] = \sum_{i=1}^M P(\omega_i) P_i = P$

- $\sigma_{k_i}^2 = N_i (1 - P_i) P_i$

- $\sigma_{\hat{p}}^2 = \sum_{i=1}^M P^2(\omega_i) \frac{P_i(1 - P_i)}{N_i}$

Avaliação de sistemas

- Portanto, o estimador é não-polarizado mas somente assintoticamente consistente. Portanto, N pequeno pode não ser confiável
- Uma estimativa aproximada do número de eventos suficiente para o conjunto de teste é

$$N \approx \frac{100}{P}$$

Então, para $P \approx 0,01$, $N \approx 10000$. Para $P \approx 0,03$, $N \approx 3000$.

Avaliação de sistemas

- Explorando o tamanho finito do banco de dados
 - **Método da resubstituição:** utiliza o mesmo conjunto de dados para treino e teste. Este método **subestima a probabilidade de erro**. A estimativa melhora para N grande e $N//$ grande
 - **Método do *Holdout*:** Dado um conjunto de dados com N eventos, dividi-lo em:
 N_1 : eventos de treino
 N_2 : eventos de teste
 $N = N_1 + N_2$
Problema: menos eventos para treinamento e para teste

Avaliação de sistemas

- Método deixa-um-fora (*leave-one-out*)

passos:

- Escolher um eventos dentre os N . Treine o classificador com $N-1$ eventos. Teste o classificador para o evento retirado do conjunto de treinamento. Conte como um erro se o evento for classificado de forma incorreta
- Repetir o procedimento acima excluindo um evento diferente cada vez
- Calcular a probabilidade de erro total

Avaliação de sistemas

- vantagens:
 - Utiliza todo o conjunto de dados para treino e para teste
 - Assegura a independência entre os eventos de treinamento e teste
- desvantagem:
 - Alta complexidade computacional
- Variantes do método excluem $k > 1$ eventos do conjunto a cada vez para reduzir a complexidade

Avaliação de sistemas

- Método da validação cruzada *k-fold*:
 - Dividir o conjunto de dados de tamanho N em k partes, resultando em k conjuntos $C_1, C_2, \dots, C_k$ de tamanho N/k
 - Escolher um conjunto C_k para teste da máquina. Treine a máquina com os $k-1$ conjuntos restantes. Teste a máquina usando o conjunto C_k que havia sido selecionado e calcule a probabilidade erro para esse conjunto
 - Repetir o processo $k-1$ vezes selecionando para teste um conjunto C_k diferente a cada vez

Avaliação de sistemas

- vantagens:
 - Reduz a complexidade computacional quando comparado ao leave-one-out
 - Assegura a independência entre os eventos de treinamento e teste
 - Fornece um indicativo da variância da máquina de aprendizado
 - Possibilita a avaliação de diferentes parametrizações da máquina de aprendizado
- desvantagem:
 - complexidade computacional

Exemplo: Método da resubstituição

Base da dados Iris, rede neural uma camada oculta com 100 neurônios

```
[[50  0  0]  
 [ 0 48  2]  
 [ 0  1 49]]
```

Probabilidade de erro 0,020 com desvio padrão de 0,011

Exemplo: Método do *holdout*

Base de dados Iris, rede neural uma camada oculta com 100 neurônios. 30% dos eventos para teste

```
[[50  0  0]  
 [ 0 48  2]  
 [ 0  1 49]]
```

Probabilidade de erro 0,022 com desvio padrão de 0,074

Exemplo: Método *leave-one-out*

Base de dados Iris, rede neural uma camada oculta com 100 neurônios

```
[[50  0  0]  
 [ 0 46  4]  
 [ 0  1 49]]
```

Probabilidade de erro 0,033 com desvio padrão de 0,014

Exemplo: Método k-fold

Base da dados Iris, rede neural uma camada oculta com 100 neurônios.
Utilizando $k=5$ partições

Probabilidade de erro para cada uma das 5 partições de teste

[0.00000000 0.00000000 0.06666667 0.06666667 0.00000000]

Probabilidade de erro média de 0,027 com desvio padrão de 0,033