

Classificação multiclasse de janelas de FBGs para demodulação de sensores LPFG

Jakson da Rocha Almeida
Universidade Federal de Juiz de Fora (UFJF)
Juiz de Fora, MG, Brasil

Felipe Oliveira Barino
Universidade Federal de Juiz de Fora (UFJF)
Juiz de Fora, MG, Brasil

Resumo—Sensores baseados em redes de período longo (LPFG) oferecem alta sensibilidade, mas sua interrogação espectral convencional exige equipamentos caros. Uma alternativa de baixo custo cascadeia a LPFG a um array de redes de Bragg (FBG): o espectro da LPFG modula as potências refletidas pelo array, e um modelo de aprendizado de máquina estima o comprimento de onda ressonante λ_{res} . Observamos que as quatro FBGs mais próximas de λ_{res} formam sempre uma janela contígua de índices, o que reduz a seleção de canais a dez classes $C_s = \{s, \dots, s + 3\}$. Avaliamos seis classificadores clássicos em 7300 amostras reais, com validação cruzada aninhada e hold-out estratificado. SVM e Random Forest atingem acurácia de 0,938 no hold-out; a análise mostra erros concentrados entre janelas adjacentes e impacto do desbalanceamento de classes. Os resultados apoiam uma arquitetura em duas etapas: classificar a janela e, em seguida, estimar λ_{res} .

Palavras-chave—Classificação multiclasse, FBG, LPFG, reconhecimento de padrões, sensores ópticos.

I. INTRODUÇÃO

Redes de Bragg em fibra (FBG) e redes de período longo (LPFG) são tecnologias consolidadas em sensoriamento óptico, porém com paradigmas espectrais distintos [1], [2]. Uma FBG reflete uma componente espectral estreita no comprimento de onda de Bragg — tipicamente com largura da ordem de 0,05 a 0,3 nm em aplicações de sensores — e desloca esse pico com deformação ou temperatura [1]. Essa assinatura estreita favorece multiplexação em comprimento de onda (WDM) ao longo de uma mesma fibra e sustenta cadeias de interrogação comerciais maduras [1]. LPFGs, por outro lado, acoplam o modo guiado fundamental a modos de revestimento que se propagam no mesmo sentido e atuam como filtros de rejeição de banda de baixas perdas de inserção [2]. O vale ressonante de uma LPFG, em contraste, pode estender-se por dezenas de nanômetros, exigindo medidas espectrais de banda larga para localizar o comprimento de onda ressonante λ_{res} [3]. Na prática, isso frequentemente implica analisadores ópticos de espectro volumosos e/ou caros — muitas vezes dedicados a um único sensor — o que limita adoção em campo e a densidade de multiplexação frente às FBGs [3].

Apesar do custo de interrogação, LPFGs permanecem atrativas: a fabricação pode ser mais simples que a de FBGs (técnicas point-by-point por arco elétrico ou laser, varredura laser, e até LPFGs dinâmicas por deformação mecânica) e a sensibilidade intrínseca a índice de refração abre aplicações em biossensores, monitoramento estrutural e indústria [3].

Desenvolver métodos de interrogação baratos e integráveis a redes já existentes é, portanto, um passo para levar LPFGs além do laboratório [3].

Uma estratégia para reutilizar a infraestrutura de FBGs consiste em cascadear a LPFG a um array de FBGs: o espectro de transmissão da LPFG modula as potências refletidas do array, e um modelo de aprendizado de máquina recupera λ_{res} a partir dessas potências [3]–[5]. Alternativas na literatura buscam reduzir custo via filtragem esparsa/densa do espectro, p.ex. com grades de guias de onda em arranjo (AWG); a linha de [3] diferencia-se ao empregar um array FBG arbitrário e um modelo de autoatenção treinado em dados sintéticos, sem exigir conhecimento prévio detalhado da transmitância da LPFG. Em [3], o sistema reporta RMSE de 0,75 nm e MAPE de 0,0335% em 73 espectros LPFG medidos, além de erro relativo inferior a 1% em uma aplicação de índice de refração. O mecanismo de atenção filtra dinamicamente canais (FBGs) mais informativos, evidenciando que apenas um subconjunto do array é decisivo para a demodulação.

Motivados por essa evidência, separamos o problema em duas etapas: (i) selecionar a *janela* de FBGs relevantes; (ii) estimar λ_{res} (já tratada em [3]). Este artigo desenvolve a etapa (i) como **classificação multiclasse**. Nos dados filtrados ($1515 < \lambda_{res} < 1585$ nm), a máscara das quatro FBGs de menor $|\lambda_{FBG,i} - \lambda_{res}|$ é sempre uma janela contígua de índices, o que reduz o espaço de decisão a dez classes $C_s = \{s, \dots, s + 3\}$, $s \in \{0, \dots, 9\}$.

Contribuições: (i) formulação da seleção de FBGs como classificação com 10 janelas contíguas, validada em dados reais; (ii) comparação de seis classificadores clássicos com validação cruzada aninhada (nested CV) e hold-out isolado; (iii) análises complementares de erro versus λ_{res} , matriz de confusão e efeito de incluir as posições Bragg.

II. TRABALHOS RELACIONADOS

A. LPFG, FBG e interrogação

Vengsarkar *et al.* introduziram LPFGs fotoinduzidas como filtros de rejeição de banda *in-fiber*, acoplando o modo fundamental a modos de revestimento copropagantes, com perdas de inserção baixas e reflexões de retorno extremamente reduzidas [2]. Kersey *et al.* revisaram sensores a grades em fibra, cobrindo sensores pontuais a FBG, grades chirpadas, lasers em fibra com FBG, LPFGs e configurações interferométricas [1]. No regime FBG, a condição de Bragg liga o

passo da grade ao índice efetivo do núcleo; uma fonte de banda larga injeta luz na fibra e uma componente estreita é refletida (e ausente na transmissão), deslocando-se com o mensurando [1]. Essa propriedade de auto-referência espectral e a facilidade de multiplexação serial tornaram FBGs centrais em estruturas inteligentes e em redes quasi-distribuídas de deformação/temperatura [1].

A assimetria espectral FBG/LPFG explica o descompasso de interrogação: FBGs operam bem com instrumentação optoeletrônica compartilhada via WDM, enquanto o vale largo da LPFG dificulta empilhar muitos sensores na mesma banda [3]. Arquiteturas híbridas exploram a maturidade dos interrogadores de FBG: o equipamento “enxerga” a LPFG indiretamente, via modulação das potências refletidas do array. Isso preserva vantagens clássicas do sensoriamento a fibra — operação eletricamente passiva no ponto de medida, imunidade a EMI e possibilidade de sensoriamento distribuído/quasi-distribuído — ao mesmo tempo em que desloca a complexidade para o processamento dos canais FBG [1].

B. Demodulação LPFG via array FBG e ML

Barino e dos Santos propuseram um interrogador de LPFG baseado em array FBG e rede neural artificial, mapeando potências em λ_{res} [4]. Em [5], a linha foi estendida a um sensor LPFG cascadeado a um array FBG com modelos de aprendizado de máquina. O trabalho subsequente [3] detalha um arranjo experimental com 13 FBGs (centros aproximados entre 1510 e 1590 nm), interrogador comercial FS22DI (HBM) e circuladores ópticos para evitar dupla passagem atenuante pela LPFG antes/depois da reflexão no array. O pré-processamento extrai comprimento de Bragg e intensidade refletida por pico (aproximação gaussiana), remove o *baseline* medido sem a LPFG e normaliza as potências pela soma — o mesmo espírito de normalização adotado neste trabalho. O modelo com autoatenção é treinado em espectros LPFG sintéticos e validado em medidas reais [3]. Conceitualmente, o modelo busca independência das posições absolutas das FBGs: a partir da força de entrada normalizada, gera um vetor de “força filtrada” que, em produto interno com os comprimentos de Bragg, estima λ_{res} [3]. A autoatenção produz um mapa dinâmico (por amostra) que modula features ocultas, atenuando canais ruidosos ou FBGs distantes do vale [3]. Treinar em sintéticos reduz a necessidade de coletar vastos conjuntos experimentais rotulados; a validação em 73 espectros medidos e em um sensor de índice de refração (erro relativo < 1%) demonstra transferência para o domínio real [3]. Em conjunto, essa linha resolve a *regressão* de λ_{res} ; permanece aberta a pergunta de reconhecimento de padrões: como declarar, de forma discreta e avaliável, *quais* FBGs devem entrar na estimação.

Declarar a seleção de canais explicitamente — em vez de deixá-la apenas implícita nos pesos de uma rede profunda — permite métricas clássicas (acurácia, F1, matriz de confusão) e facilita diagnóstico em uma cascata classificação→regressão. Além disso, um estágio de classificação raso pode ser retreinado quando o espaçamento do array FBG muda, enquanto

o regressor de [3] permanece responsável pela precisão subnanométrica de λ_{res} . A formulação multiclasse deste artigo pode ser lida, portanto, como uma versão *explícita* e avaliável da filtragem de canais que a autoatenção realiza de modo contínuo.

C. Classificadores empregados

Adotamos métodos clássicos e bem documentados em reconhecimento de padrões [6]. Máquinas de vetores de suporte (SVM) maximizam a margem de separação e, com kernels, tratam fronteiras não lineares; a formulação original de Cortes e Vapnik enfatiza generalização via controle de capacidade [7] — usamos kernel RBF. Florestas aleatórias agregam árvores treinadas com aleatoriedade em amostras/atributos; o erro de generalização converge com o número de árvores e depende da força individual e da correlação entre elas, com robustez favorável a ruído em relação a certos esquemas de boosting [8]. Também avaliamos k -vizinhos mais próximos (kNN), perceptron multicamadas (MLP), AdaBoost com árvores de decisão e um baseline linear por mínimos quadrados regularizados (RidgeClassifier, denotado MQ). A escolha privilegia reprodutibilidade e contraste entre indutores lineares e não lineares, em vez de competir diretamente com a arquitetura profunda de [3] na regressão. A validação cruzada aninhada (nested CV), recomendada para evitar viés otimista ao ajustar hiperparâmetros [6], é o protocolo de seleção de modelos deste artigo.

III. FORMULAÇÃO DO PROBLEMA

Cada amostra n fornece potências $\mathbf{x}^{(n)} \in \mathbb{R}^{13}$, posições $\lambda_{\text{FBG}}^{(n)} \in \mathbb{R}^{13}$ e o alvo $\lambda_{res}^{(n)}$. O erro $e_i = |\lambda_{\text{FBG},i} - \lambda_{res}|$ induz a máscara top-4 (quatro menores e_i). Fixamos $k = 4$ por coerência com a prática de [3], em que um pequeno subconjunto de canais concentra a informação. No conjunto filtrado, essa máscara é *sempre* contígua; logo o rótulo oficial é

$$y = s \in \{0, \dots, 9\}, \quad C_s = \{s, s+1, s+2, s+3\}. \quad (1)$$

O classificador recebe $\mathbf{x}$ (ou $\mathbf{x}$ concatenado a λ_{FBG} na ablação) e prediz s ; a máscara implícita é C_s . A Fig. 1 resume o esquema físico e a janela-classe em torno de λ_{res} .

A contiguidade não é uma restrição artificial: decorre da ordenação espectral das FBGs ao longo do eixo de comprimento de onda. Janelas vizinhas C_s e C_{s+1} compartilham três índices e diferem por um, o que antecipa confusões adjacentes na matriz de erros.

IV. METODOLOGIA

A. Dados e pré-processamento

Usamos o conjunto medido associado a [3]. No arranjo experimental de referência, LPFG e array de 13 FBGs (centros aproximados entre 1510 e 1590 nm) são cascadeados e lidos por um interrogador comercial de FBGs; a LPFG modula o perfil de refletividade visto pelo interrogador [3]. Há 8200 amostras no arquivo bruto; o filtro $1515 < \lambda_{res} < 1585$ nm




Figura 1. Esquema: LPFG (Lorentziana ilustrativa), λ_{res} e janela-classe C_s no array de 13 FBGs.

Tabela I
DISTRIBUIÇÃO DAS 10 CLASSES NO CONJUNTO FILTRADO ($N = 7300$).

Classe	n	%	Classe	n	%
C_0	520	7,12	C_5	542	7,42
C_1	1257	17,22	C_6	236	3,23
C_2	2089	28,62	C_7	696	9,53
C_3	89	1,22	C_8	270	3,70
C_4	1501	20,56	C_9	100	1,37

— interno à faixa coberta pelo array — produz 7300 exemplos utilizáveis. As potências são normalizadas por amostra (subtração do mínimo e divisão pela soma), como em [3], garantindo invariância a offset e escala global. A Fig. 2 exibe 73 amostras espalhadas ao longo do intervalo útil e ordenadas por λ_{res} : a faixa de alta potência desloca-se pelas colunas do array conforme o vale da LPFG varre as posições das FBGs, o que evidencia a estrutura explorada pela classificação em janelas.

A Tabela I quantifica o desbalanceamento. C_2 concentra quase 29% dos exemplos, enquanto C_3 e C_9 ficam abaixo de 1,5%. Esse perfil explica por que F1 macro tende a ficar abaixo de F1 weighted e por que o AdaBoost necessitou de árvores mais profundas e pesos de classe.

B. Classificadores e hiperparâmetros

Comparamos kNN, SVM RBF, MLP, Random Forest, AdaBoost e MQ. kNN, SVM, MLP e MQ usam `StandardScaler` ajustado apenas no treino de cada partição. As grades de busca incluem, entre outros: $k \in \{3, 5, 7, 11\}$ e pesos uniforme/distância (kNN); $C \in \{0, 1, 10\}$ e $\gamma \in \{\text{scale}, 0, 1\}$ (SVM); arquiteturas e regularização α (MLP); profundidade e número de árvores (RF); e, no AdaBoost, profundidade da árvore base $\in \{2, 3, 4\}$, número de estimadores $\in \{100, 200\}$ e taxa de aprendizado $\in \{0, 3, 0, 5, 1, 0\}$, sempre com pesos de classe balanceados na árvore base. O consenso do AdaBoost no desenvolvimento foi profundidade 4, 200 estimadores e taxa 0,3.

C. Protocolo de avaliação

Reservamos 20% como hold-out estratificado por classe (1460 amostras), intacto até o teste final. No desenvolvimento (5840), usamos `StratifiedKFold` com 5 folds. A estratificação por y evita folds sem representantes de classes raras, o

Tabela II
DESEMPENHO MULTICLASSE: CV (MÉDIA $\pm$ DESVIO) E HOLD-OUT (HO).

Método	Acc. CV	$F1_w$ CV	Acc. HO	$F1_w$ HO
SVM	0,934 $\pm$ 0,004	0,927	0,938	0,931
RF	0,929 $\pm$ 0,004	0,923	0,938	0,932
AdaBoost	0,924 $\pm$ 0,004	0,923	0,923	0,925
MLP	0,919 $\pm$ 0,011	0,908	0,933	0,923
kNN	0,907 $\pm$ 0,003	0,901	0,919	0,911
MQ	0,779 $\pm$ 0,007	0,736	0,789	0,750

que seria especialmente problemático para C_3 e C_9 . Hiperparâmetros foram escolhidos por nested CV (`GridSearchCV` interno, 3 folds, `scorer = acurácia`), reduzindo viés otimista de ajustar e avaliar na mesma partição [6]. Os modelos de consenso foram retreinados no desenvolvimento completo e avaliados uma única vez no hold-out. Reportamos acurácia e F1 weighted na tabela principal; F1 macro e matrizes de confusão sustentam a discussão de classes raras. Implementações seguem a biblioteca `scikit-learn`, com semente fixa para reprodutibilidade.

V. RESULTADOS

A. Desempenho agregado

A Tabela II coloca CV e hold-out na mesma visão. SVM lidera a CV (0,934 $\pm$ 0,004) e empata com Random Forest no hold-out (0,938). AdaBoost, após o ajuste descrito, aproxima-se dos líderes (0,923 no hold-out) e fica bem acima do baseline linear MQ (0,789), indicando que a fronteira potências $\rightarrow$ janela é essencialmente não linear. A diferença entre F1 weighted e F1 macro — p.ex., 0,931 contra 0,874 para o SVM no hold-out — é observada em todos os métodos e acompanha o desbalanceamento da Tabela I.

B. Erros versus λ_{res}

A Fig. 3 mostra a acurácia do SVM por faixas de λ_{res} (predições da CV empilhadas). A degradação concentra-se em ≈ 1548 – 1580 nm, região em que janelas periféricas e amostras mais escassas se combinam; a borda inferior do intervalo, em contraste, mantém acurácia próxima de 0,96, de modo que a hipótese de que “bordas espectrais pioram” não se confirma de forma simétrica nestes dados. Essa visão é complementar à Tabela II: a acurácia média global esconde uma heterogeneidade espectral relevante para a aplicação.

C. Matriz de confusão

A Fig. 4 compara as matrizes do SVM e do Random Forest no hold-out, normalizadas por linha. Os erros residuais ocorrem sobretudo entre classes adjacentes — coerente com a sobreposição de três FBGs entre C_s e C_{s+1} . Do ponto de vista da cascata classificação $\rightarrow$ regressão, confundir janelas vizinhas é menos grave do que saltos longos no array, pois o subconjunto de canais permanece parcialmente correto. O padrão qualitativo semelhante nos dois melhores métodos reforça que o empate em acurácia não é coincidência isolada: ambos capturam a geometria das janelas no espaço de potências.




Figura 2. Potências FBG normalizadas (73 de 7300 amostras, ordenadas por λ_{res}). A faixa clara em diagonal indica o deslocamento do padrão de potências pelo array à medida que λ_{res} cresce.




Figura 3. Acurácia do SVM por bin de λ_{res} (CV empilhada).

Diferenças pontuais em classes raras são esperadas dada a baixa contagem absoluta (Tabela I).

D. Ablação: posições Bragg

Concatenar λ_{FBG} às potências altera o ranking de forma desigual: MLP (+0,029 em acurácia CV), Random Forest (+0,019) e MQ (+0,041) melhoram; o SVM permanece quase neutro (−0,001); o kNN piora (−0,050). A Fig. 5 resume essa comparação lado a lado; o AdaBoost foi omitido porque a ablação foi executada antes do reajuste de hiperparâmetros descrito na metodologia, e o resultado antigo não seria comparável. Interpretamos o prejuízo do kNN como sensibilidade à mudança de escala e de dimensionalidade sob distância





Figura 4. Matrizes de confusão no hold-out (% por linha): esquerda, SVM; direita, Random Forest.




Figura 5. Acurácia CV: somente potências versus potências concatenadas às posições Bragg (AdaBoost omitido; ver texto).

euclidiana. Para o MQ, as posições adicionam informação linearmente útil que as potências sozinhas não carregam de modo suficiente; para o SVM RBF, as potências já induzem uma margem competitiva sem as coordenadas Bragg.

VI. DISCUSSÃO

Formalizar a seleção de FBGs como dez classes alinha o problema à avaliação clássica de reconhecimento de padrões e torna explícito o conjunto de decisões [6]. Em relação à regressão de [3], o classificador atua como estágio anterior: se C_s for predito corretamente, um estimador de λ_{res} pode operar apenas sobre quatro canais, potencialmente reduzindo ruído de FBGs irrelevantes — hipótese ainda não medida em RMSE.

Do ponto de vista de engenharia de sensores, a cascata classificação→regressão também facilita diagnóstico: falhas de demodulação podem ser atribuídas à escolha da janela

errada (Fig. 4) ou à estimação contínua dentro da janela correta. Além disso, um classificador raso (SVM/RF) é barato de retreinar quando o array FBG é recalibrado, enquanto o modelo de autoatenção de [3] permanece responsável pela precisão subnanométrica de λ_{res} .

O desempenho de SVM/RF (0,938 no hold-out) indica que a etapa de janela é tratável com modelos clássicos. Por outro lado, o desbalanceamento (Tabela I) e a otimização por acurácia favorecem classes majoritárias: estratégias futuras incluem scorer macro-F1, reamostragem ou custos assimétricos, sobretudo para C_3 e C_9 . Confusões adjacentes, embora preferíveis a erros longos, ainda podem deslocar a estimação de λ_{res} em frações de nanômetro se a regressão for sensível ao canal excluído/incluído indevidamente.

Limitações: (i) não quantificamos o ganho de RMSE ao fixar a janela antes da regressão; (ii) o protocolo usa um único hold-out (além da CV), suficiente para o escopo deste estudo, porém sensível à partição; (iii) não exploramos modelos profundos na classificação, propositalmente, para isolar o ganho da formulação multiclasse; (iv) a curva Lorentziana da Fig. 1 é ilustrativa, não um espectro medido.

VII. CONCLUSÃO

Formulamos a seleção das FBGs relevantes à demodulação de LPFG como classificação multiclasse com dez janelas contíguas C_s , explorando a contiguidade observada nos dados filtrados. Com potências normalizadas de um array de 13 FBGs, nested CV e hold-out estratificado, SVM e Random Forest alcançaram acurácia 0,938 no teste final; erros remanescentes concentram-se em classes adjacentes e em faixas de λ_{res} menos povoadas. A ablação com posições Bragg mostra ganhos dependentes do indutor, reforçando que a representação

deve ser escolhida junto com o classificador. O trabalho estabelece a Parte 1 de uma arquitetura em cascata cuja Parte 2 — estimação de λ_{res} restrita à janela predita, na linha de [3] — permanece como próximo passo experimental.

REFERÊNCIAS

- [1] A. D. Kersey, M. A. Davis, H. J. Patrick, M. LeBlanc, K. P. Koo, C. G. Askins, M. A. Putnam, and E. J. Friebele, “Fiber grating sensors,” *J. Lightwave Technol.*, vol. 15, no. 8, pp. 1442–1463, 1997, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/50.618320>
- [2] A. M. Vengsarkar, P. J. Lemaire, J. B. Judkins, V. Bhatia, T. Erdogan, and J. E. Sipe, “Long-period fiber gratings as band-rejection filters,” *J. Lightwave Technol.*, vol. 14, no. 1, pp. 58–65, 1996, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/50.476137>
- [3] F. O. Barino and A. B. dos Santos, “Self-attention AI model for practical sensor networking: Demodulation of long-period fiber grating sensor cascaded with FBG sensor array,” *IEEE Trans. Instrum. Meas.*, vol. 74, pp. 1–10, 2025, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/TIM.2025.3573014>
- [4] —, “LPG interrogator based on FBG array and artificial neural network,” *IEEE Sensors J.*, vol. 20, no. 23, pp. 14 187–14 194, 2020, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/JSEN.2020.3007957>
- [5] F. O. Barino, V. Pamplona, A. L. M. Marcato, R. M. Capelini, C. C. dos Santos, L. d. M. Honório, C. Duarte, F. Hamaji, and A. B. dos Santos, “Demodulation of an LPFG sensor cascaded by an FBG sensor array using machine learning,” in *Proc. Latin Amer. Workshop Opt. Fiber Sensors (LAWOFS)*, 2024, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.23919/LAWOFS62242.2024.10560772>
- [6] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1007/978-0-387-84858-7>
- [7] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1007/BF00994018>
- [8] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1023/A:1010933404324>