

Classificação multiclasse de janelas de FBGs para demodulação de sensores LPFG

Jakson da Rocha Almeida
Universidade Federal de Juiz de Fora (UFJF)
Juiz de Fora, MG, Brasil

Resumo—Sensores baseados em redes de período longo (LPFG) são úteis, mas sua interrogação por analisador óptico de espectro é cara. Uma alternativa é modular o espectro da LPFG com um array de redes de Bragg (FBG) e estimar o comprimento de onda ressonante λ_{res} por aprendizado de máquina. Observamos que a máscara das quatro FBGs mais próximas de λ_{res} é sempre uma janela contígua no array; isso reduz o problema a dez classes $C_s = \{s, \dots, s+3\}$, $s \in \{0, \dots, 9\}$. Seis classificadores clássicos foram avaliados com validação cruzada estratificada por classe e hold-out isolado, sobre dados reais autorizados. Com hiperparâmetros ajustados por nested CV (scorer = acurácia), o SVM RBF obteve acurácia média de 0,934 na CV e 0,938 no hold-out (empatado com Random Forest no teste final). A análise mostra desbalanceamento acentuado entre classes e ganho de incluir as posições Bragg em alguns métodos.

Index Terms—Classificação multiclasse, FBG, LPFG, reconhecimento de padrões, sensores ópticos.

I. INTRODUÇÃO

Redes de período longo em fibra (LPFG) formam sensores versáteis [1], porém a leitura convencional do vale ressonante exige instrumentação espectral de alto custo. Redes de Bragg (FBG) podem atuar como banco de filtros para modular o espectro da LPFG [2]–[4].

Barino e dos Santos demonstraram demodulação de LPFG a partir das potências de um array de FBGs com uma rede com autoatenção [4]. Motivados pela ideia de que apenas um subconjunto de FBGs é relevante, formulamos a *Parte 1*: classificar a **janela** de FBGs de interesse antes de uma eventual interrogação/regressão (Parte 2).

Contribuições: (i) redução do problema a 10 classes de janelas contíguas a partir de dados reais; (ii) comparação de seis classificadores da disciplina com CV aninhada e hold-out; (iii) análise de erros versus λ_{res} e do uso das posições FBG.

II. TRABALHOS RELACIONADOS

A interrogação de LPFG com arrays FBG e aprendizado de máquina foi explorada em [3]–[5], com ênfase na estimação de λ_{res} . O presente trabalho não substitui esses modelos de regressão: concentra-se na seleção das FBGs relevantes.

Empregamos métodos clássicos — kNN, SVM [6], MLP, florestas aleatórias [7], AdaBoost e classificador linear (Ridge) — conforme o repertório da disciplina e práticas de avaliação estatística [8].

III. FORMULAÇÃO DO PROBLEMA

Cada amostra n fornece potências $\mathbf{x}^{(n)} \in \mathbb{R}^{13}$, posições $\lambda_{\text{FBG}}^{(n)} \in \mathbb{R}^{13}$ e o alvo $\lambda_{res}^{(n)}$. Define-se o erro $e_i = |\lambda_{\text{FBG},i} -$




Figura 1. Esquema da LPFG, do array de 13 FBGs e de uma janela-classe em torno de λ_{res} .

$\lambda_{res}|$ e a máscara top-4 nos menores e_i . No conjunto filtrado, essa máscara é *sempre* uma janela contígua; portanto o rótulo oficial é a classe

$$y = s \in \{0, \dots, 9\}, \quad C_s = \{s, s+1, s+2, s+3\}. \quad (1)$$

O classificador recebe $\mathbf{x}$ e prediz s ; a máscara implícita é C_s (Fig. 1).

IV. METODOLOGIA

A. Dados e pré-processamento

Usamos o conjunto medido disponibilizado em [4] (autorização de uso para este trabalho). Há 8200 amostras; após o filtro $1515 < \lambda_{res} < 1585$ nm restam 7300. As potências são normalizadas por amostra (subtração do mínimo e soma unitária), como em [4]. As dez classes são desbalanceadas (ex.: C_2 com $\approx 29\%$ das amostras e C_3 com $\approx 1,2\%$).

B. Classificadores

Comparamos: kNN; SVM RBF; MLP; Random Forest; AdaBoost; e RidgeClassifier (MQ/linear). kNN, SVM, MLP e MQ usam `StandardScaler` ajustado apenas no treino de cada fold.

C. Avaliação

Reservamos 20% como hold-out estratificado por **classe** (1460 amostras). No desenvolvimento (5840), usamos `StratifiedKfold` com 5 folds. Hiperparâmetros foram escolhidos por nested CV (`GridSearchCV` interno de 3 folds, scorer = acurácia). Métricas principais: acurácia, F1 macro e F1 weighted; matrizes de confusão 10×10 . Após o tuning, os modelos de consenso foram retreinados no desenvolvimento e avaliados uma única vez no hold-out.

Tabela I
CV ESTRATIFICADA (MÉDIA $\pm$ DESVIO).

Método	Acurácia	F1 weight.	F1 macro
SVM	0,934 $\pm$ 0,004	0,927	0,866
RF	0,929 $\pm$ 0,003	0,923	0,857
MLP	0,919 $\pm$ 0,010	0,908	0,819
kNN	0,907 $\pm$ 0,003	0,901	0,830
MQ	0,779 $\pm$ 0,006	0,736	0,580
AdaBoost	0,650 $\pm$ 0,010	0,554	0,365

Tabela II
HOLD-OUT ÚNICO (TREINO NO DESENVOLVIMENTO COMPLETO).

Método	Acurácia	F1 weight.	F1 macro
SVM	0,938	0,931	0,874
RF	0,938	0,932	0,878
MLP	0,933	0,923	0,846
kNN	0,919	0,911	0,824
MQ	0,789	0,750	0,613
AdaBoost	0,543	0,409	0,209




Figura 2. Comparação dos seis métodos na CV (acurácia).




Figura 3. Exemplo real: janela verdadeira versus prevista (SVM).

V. RESULTADOS

A. Desempenho principal

A Tabela I resume a CV com modelos afinados (só potências). O SVM lidera em acurácia ($0,934 \pm 0,004$), seguido de Random Forest e MLP. O baseline linear (MQ) e o AdaBoost ficam claramente atrás. No hold-out (Tabela II), SVM e Random Forest empatam em 0,938.

A Fig. 2 compara as métricas na CV; a Fig. 3 ilustra janela verdadeira versus prevista (SVM).




Figura 4. Acurácia média por bin de λ_{res} (CV empilhada, SVM).




Figura 5. Matrizes de confusão 10×10 normalizadas por linha (hold-out).

B. Análise crítica

Erros versus λ_{res} . Para o SVM, os bins mais difíceis situam-se em torno de 1548–1580 nm (acurácia $\approx 0,87$), enquanto a faixa 1531–1534 nm atinge $\approx 0,996$ (Fig. 4).

Posições FBG. Concatenar λ_{FBG} às potências melhora MLP (+0,029), RF (+0,019) e MQ (+0,041), é quase neutro para o SVM e *prejudica* o kNN (−0,050).

VI. DISCUSSÃO

A formulação multiclasse torna explícito o conjunto de decisões possíveis e alinha a avaliação à disciplina (acurácia e matriz de confusão). O desempenho elevado do SVM/RF reforça a viabilidade de uma arquitetura em duas etapas: seleção da janela seguida de estimação de λ_{res} [4]. Limitações: classes raras (C_3 , C_9); impacto na regressão ainda não medido; AdaBoost fraco neste problema.

VII. CONCLUSÃO

Formulamos a seleção de FBGs relevantes à demodulação de LPFG como classificação multiclasse com 10 janelas contíguas. Com dados reais, nested CV e hold-out isolado, SVM e Random Forest obtiveram acurácia $\approx 0,938$ no hold-out. Próximos passos incluem acoplar a janela ao modelo de interrogação e avaliar o ganho em RMSE de λ_{res} .

AGRADECIMENTOS

Agradecemos ao Dr. Felipe Oliveira Barino pela autorização de uso dos dados e código associados a [4].

REFERÊNCIAS

- [1] A. M. Vengsarkar, P. J. Lemaire, J. B. Judkins, V. Bhatia, T. Erdogan, and J. E. Sipe, “Long-period fiber gratings as band-rejection filters,” *J. Lightwave Technol.*, vol. 14, no. 1, pp. 58–65, 1996.
- [2] A. D. Kersey, M. A. Davis, H. J. Patrick, M. LeBlanc, K. P. Koo, C. G. Askins, M. A. Putnam, and E. J. Friebele, “Fiber grating sensors,” *J. Lightwave Technol.*, vol. 15, no. 8, pp. 1442–1463, 1997.
- [3] F. O. Barino and A. B. dos Santos, “LPG interrogator based on FBG array and artificial neural network,” *IEEE Sensors J.*, vol. 20, no. 23, pp. 14 187–14 194, 2020.
- [4] —, “Self-attention AI model for practical sensor networking: Demodulation of long-period fiber grating sensor cascaded with FBG sensor array,” *IEEE Trans. Instrum. Meas.*, vol. 74, pp. 1–10, 2025.
- [5] F. O. Barino, V. Pamplona, A. L. M. Marcato, R. M. Capelini, C. C. dos Santos, L. d. M. Honório, C. Duarte, F. Hamaji, and A. B. dos Santos, “Demodulation of an LPFG sensor cascaded by an FBG sensor array using machine learning,” in *Proc. Latin Amer. Workshop Opt. Fiber Sensors (LAWOFS)*, 2024.
- [6] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [7] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [8] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.