

Classificação multi-rótulo de FBGs relevantes para demodulação de sensores LPFG

Jakson da Rocha Almeida
Universidade Federal de Juiz de Fora (UFJF)
Juiz de Fora, MG, Brasil

Resumo—Sensores baseados em redes de período longo (LPFG) são úteis, mas sua interrogação por analisador óptico de espectro é cara. Uma alternativa é modular o espectro da LPFG com um array de redes de Bragg (FBG) e estimar o comprimento de onda ressonante λ_{res} por aprendizado de máquina. Este trabalho aborda a seleção das FBGs mais próximas de λ_{res} como classificação multi-rótulo: a partir das potências ópticas normalizadas de 13 FBGs, prediz-se uma máscara top- k ($k=4$). Seis classificadores clássicos foram avaliados com validação cruzada estratificada e hold-out isolado, sobre dados reais autorizados. Com hiperparâmetros ajustados por nested CV, o SVM one-vs-rest obteve Jaccard médio de 0,974 na CV e 0,975 no hold-out. A análise mostra que o pior desempenho não ocorre nas bordas espectrais e que incluir as posições das FBGs beneficia alguns métodos, mas não o SVM.

Index Terms—Classificação multi-rótulo, FBG, LPFG, reconhecimento de padrões, sensores ópticos.

I. INTRODUÇÃO

Redes de período longo em fibra (LPFG) formam sensores versáteis para grandezas como índice de refração e temperatura [1]. Contudo, a leitura convencional do vale ressonante exige instrumentação espectral de alto custo. Redes de Bragg (FBG) são amplamente usadas em sensores e filtros [2] e podem atuar como banco de filtros estáticos para modular o espectro da LPFG [3], [4].

Barino e dos Santos demonstraram demodulação de LPFG a partir das potências de um array de FBGs com uma rede neural com autoatenção [4]. A atenção sugere que apenas um subconjunto de FBGs é relevante para localizar λ_{res} . Motivados por essa observação, formulamos explicitamente a *Parte 1* do problema: classificar quais FBGs devem compor a máscara de interesse antes de uma eventual interrogação/regressão (*Parte 2*).

Contribuições: (i) definição multi-rótulo da máscara top- k a partir de dados reais; (ii) comparação de seis classificadores da disciplina com CV aninhada e hold-out; (iii) análise de erros versus λ_{res} , de $k \in \{3, 4, 5\}$ e do uso das posições FBG.

II. TRABALHOS RELACIONADOS

A interrogação de LPFG com arrays FBG e aprendizado de máquina foi explorada em [3]–[5], com ênfase na estimação de λ_{res} . O presente trabalho não substitui esses modelos de regressão: concentra-se na seleção das FBGs relevantes, alinhada à ideia de filtragem dinâmica por atenção.

A classificação multi-rótulo admite métricas específicas (Hamming, Jaccard por amostra, exact match) [6], [7]. Empregamos métodos clássicos — kNN, SVM [8], MLP, florestas




Figura 1. Esquema da LPFG, do array de 13 FBGs e da máscara top-4 em torno de λ_{res} .

aleatórias [9], AdaBoost e mínimos quadrados — conforme o repertório da disciplina e práticas de avaliação estatística [10].

III. FORMULAÇÃO DO PROBLEMA

Cada amostra n fornece potências $\mathbf{x}^{(n)} \in \mathbb{R}^{13}$, posições $\lambda_{\text{FBG}}^{(n)} \in \mathbb{R}^{13}$ e o alvo $\lambda_{res}^{(n)}$. Define-se o erro $e_i = |\lambda_{\text{FBG},i} - \lambda_{res}|$ e a máscara $y \in \{0, 1\}^{13}$ com $y_i = 1$ nos k índices de menor e_i (Fig. 1). Adotamos $k=4$ como configuração principal, coerente com a heurística discutida com o autor dos dados.

O classificador recebe $\mathbf{x}$ (potências normalizadas) e produz escores por canal; a predição final seleciona os k maiores escores, garantindo cardinalidade fixa e alinhamento ao rótulo.

IV. METODOLOGIA

A. Dados e pré-processamento

Usamos o conjunto medido disponibilizado em [4] (autorização de uso para este trabalho). Há 8200 amostras; após o filtro aberto $1515 < \lambda_{res} < 1585$ nm restam 7300. As potências são normalizadas por amostra (subtração do mínimo e soma unitária), como no pipeline de avaliação de [4]. A máscara top-4 é desbalanceada por canal: FBGs centrais são positivas com bem maior frequência que as das bordas do array.

B. Classificadores

Comparamos: kNN; SVM RBF em one-vs-rest; MLP; Random Forest; AdaBoost em one-vs-rest; e regressão linear multi-saída (MQ), com top- k nos valores previstos. kNN, SVM, MLP e MQ usam StandardScaler ajustado apenas no treino de cada fold.

Tabela I
CV ESTRATÉGIA A (MÉDIA $\pm$ DESVIO, $k=4$).

Método	Jaccard	Exact	F1 mic.	Hamm.
SVM	0,974 $\pm$ 0,003	0,935	0,984	0,010
RF	0,973 $\pm$ 0,002	0,933	0,983	0,010
AdaBoost	0,973 $\pm$ 0,004	0,932	0,983	0,011
MLP	0,965 $\pm$ 0,006	0,912	0,978	0,014
kNN	0,964 $\pm$ 0,002	0,910	0,978	0,014
MQ	0,922 $\pm$ 0,005	0,805	0,951	0,030

Tabela II
HOLD-OUT ÚNICO (TREINO NO DESENVOLVIMENTO COMPLETO).

Método	Jaccard	Exact	F1 micro
SVM	0,975	0,938	0,985
RF	0,974	0,936	0,984
MLP	0,974	0,934	0,984
AdaBoost	0,973	0,934	0,983
kNN	0,967	0,918	0,979
MQ	0,933	0,832	0,958

C. Avaliação

Reservamos 20% das amostras como hold-out estratificado por quantis de λ_{res} (1460 amostras), sem uso em ajuste. No desenvolvimento (5840), usamos StratifiedKFold com 5 folds (estratégia A). Hiperparâmetros foram escolhidos por nested CV (GridSearchCV interno de 3 folds, scorer = Jaccard top- k). A métrica principal é o Jaccard por amostra; reportamos também exact match, F1 micro/macro e Hamming. Após o tuning, os modelos de consenso foram retreinados no desenvolvimento completo e avaliados *uma única vez* no hold-out.

V. RESULTADOS

A. Desempenho principal

A Tabela I resume a CV com modelos afinados ($k=4$, só potências). O SVM lidera em Jaccard ($0,974 \pm 0,003$), seguido de perto por Random Forest e AdaBoost. O MQ permanece como baseline linear mais fraco. No hold-out (Tabela II), a ordem se mantém: SVM com Jaccard 0,975, confirmando generalização sem retuning no teste final.

A Fig. 2 compara as métricas na CV; a Fig. 3 ilustra um acerto e um erro típico do SVM.

B. Análise crítica

Erros versus λ_{res} . A hipótese de piora nas bordas espectrais não se confirma: para o SVM, o bin mais difícil situa-se em torno de 1553–1564 nm (Jaccard $\approx 0,91$), enquanto bordas e centro permanecem $\geq 0,97$ (Fig. 4).

Efeito de k . Para $k \in \{3, 4, 5\}$, o SVM permanece o melhor; o Jaccard é mais alto em $k=3$ (0,985), o que é esperado por ser um problema de menor cardinalidade. Mantemos $k=4$ por alinhamento à heurística alvo.

Posições FBG. Concatenar λ_{FBG} às potências melhora RF, AdaBoost, MLP e MQ ($\approx +0,008$ a $+0,015$ em Jaccard), é




Figura 2. Comparação dos seis métodos na CV ($k=4$).




Figura 3. Exemplo real: máscara verdadeira versus prevista (SVM).




Figura 4. Jaccard médio por bin de λ_{res} (CV empilhada).




Figura 5. Taxa de erro por canal FBG.

quase neutro para o SVM e *prejudica* o kNN ($-0,022$). Com posições, a RF atinge $\approx 0,981$ na CV.

A Fig. 5 evidencia erros maiores em canais com suporte positivo baixo (bordas do array), coerente com o desbalançamento da máscara.

VI. DISCUSSÃO

A classificação da máscara é resolúvel com métodos clássicos e alto Jaccard, o que reforça a viabilidade de uma arquitetura em duas etapas: seleção de FBGs seguida de estimação de λ_{res} (como em [4]). Limitações: não medimos ainda o impacto da máscara na regressão; não exploramos SMOTE multi-rótulo.

VII. CONCLUSÃO

Formulamos e avaliamos a seleção de FBGs relevantes à demodulação de LPFG como classificação multi-rótulo top-4. Com dados reais, nested CV e hold-out isolado, o SVM RBF one-vs-rest obteve o melhor compromisso (Jaccard $\approx 0,975$ no hold-out). Próximos passos incluem acoplar a máscara ao modelo de interrogação e avaliar o ganho em RMSE de λ_{res} .

AGRADECIMENTOS

Agradecemos ao Dr. Felipe Oliveira Barino pela autorização de uso dos dados e código associados a [4].

REFERÊNCIAS

- [1] A. M. Vengsarkar, P. J. Lemaire, J. B. Judkins, V. Bhatia, T. Erdogan, and J. E. Sipe, "Long-period fiber gratings as band-rejection filters," *J. Lightwave Technol.*, vol. 14, no. 1, pp. 58–65, 1996.
- [2] A. D. Kersey, M. A. Davis, H. J. Patrick, M. LeBlanc, K. P. Koo, C. G. Askins, M. A. Putnam, and E. J. Friebele, "Fiber grating sensors," *J. Lightwave Technol.*, vol. 15, no. 8, pp. 1442–1463, 1997.
- [3] F. O. Barino and A. B. dos Santos, "LPG interrogator based on FBG array and artificial neural network," *IEEE Sensors J.*, vol. 20, no. 23, pp. 14 187–14 194, 2020.
- [4] —, "Self-attention AI model for practical sensor networking: Demodulation of long-period fiber grating sensor cascaded with FBG sensor array," *IEEE Trans. Instrum. Meas.*, vol. 74, pp. 1–10, 2025.
- [5] F. O. Barino, V. Pamplona, A. L. M. Marcato, R. M. Capelini, C. C. dos Santos, L. d. M. Honório, C. Duarte, F. Hamaji, and A. B. dos Santos, "Demodulation of an LPFG sensor cascaded by an FBG sensor array using machine learning," in *Proc. Latin Amer. Workshop Opt. Fiber Sensors (LAWOFS)*, 2024.
- [6] G. Tsoumakas and I. Katakis, "Multi-label classification: An overview," *Int. J. Data Warehousing Mining*, vol. 3, no. 3, pp. 1–13, 2007.
- [7] M.-L. Zhang and Z.-H. Zhou, "A review on multi-label learning algorithms," *IEEE Trans. Knowl. Data Eng.*, vol. 26, no. 8, pp. 1819–1837, 2014.
- [8] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [9] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [10] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.