

Classificação multiclasse de janelas de FBGs para demodulação de sensores LPFG

Jakson da Rocha Almeida
Universidade Federal de Juiz de Fora (UFJF)
Juiz de Fora, MG, Brasil

Felipe Oliveira Barino
Departamento de Circuitos, UFJF
Juiz de Fora, MG, Brasil

Resumo—Sensores LPFG oferecem alta sensibilidade, mas sua interrogação espectral convencional é cara. Uma alternativa *modula o espectro da LPFG com um array de FBGs e estima λ_{res} por aprendizado de máquina*. Observamos que as quatro FBGs mais próximas de λ_{res} formam sempre uma janela contígua; isso permite reduzir a seleção de canais a dez classes $C_s = \{s, \dots, s+3\}$. Avaliamos seis classificadores clássicos em 7300 amostras reais, com nested CV e hold-out estratificado. SVM e Random Forest atingem acurácia 0,938 no hold-out; a análise mostra erros predominantemente entre janelas adjacentes e impacto do desbalanceamento de classes. O resultado apoia uma arquitetura em duas etapas: classificar a janela e, em seguida, estimar λ_{res} .

Index Terms—Classificação multiclasse, FBG, LPFG, reconhecimento de padrões, sensores ópticos.

I. INTRODUÇÃO

Redes de período longo em fibra (LPFG) acoplam o modo fundamental a modos de revestimento e atuam como filtros de rejeição de banda, viabilizando sensores de índice de refração, temperatura e outras grandezas [1]. Em contraste, as redes de Bragg (FBG) apresentam pico de reflexão estreito e contam com cadeias de interrogação relativamente maduras e comercialmente disponíveis [2]. Essa assimetria faz com que a leitura direta do vale ressonante de uma LPFG — tipicamente via analisador óptico de espectro — permaneça um obstáculo de custo para aplicações em campo e para multiplexação em redes densas de sensores.

Uma linha recente combina um array de FBGs, operando como banco de filtros, com modelos de aprendizado de máquina para recuperar o comprimento de onda ressonante λ_{res} da LPFG a partir das potências refletidas [3]–[5]. Em [5], um modelo com autoatenção treinado em dados sintéticos e validado em medidas reais reporta RMSE de 0,75 nm e MAPE de 0,0335% em 73 espectros LPFG, além de erro relativo inferior a 1% em uma aplicação de índice de refração. O mecanismo de atenção concentra-se em canais espectrais (FBGs) mais informativos, sugerindo que apenas um subconjunto do array é decisivo para a demodulação. Declarar esse subconjunto de forma discreta — antes da regressão — é o objeto deste artigo.

Motivados por essa evidência, separamos o problema em duas etapas: (i) selecionar a *janela* de FBGs relevantes; (ii) estimar λ_{res} (já tratada em [5]). Este artigo desenvolve a etapa (i) como **classificação multiclasse**. Nos dados filtrados ($1515 < \lambda_{res} < 1585$ nm), a máscara das quatro FBGs de menor $|\lambda_{FBG,i} - \lambda_{res}|$ é sempre uma janela contígua

de índices, o que reduz o espaço de decisão a dez classes $C_s = \{s, \dots, s+3\}$, $s \in \{0, \dots, 9\}$.

Contribuições: (i) formulação da seleção de FBGs como classificação com 10 janelas contíguas, validada em dados reais; (ii) comparação de seis classificadores clássicos com nested CV e hold-out isolado; (iii) análises complementares de erro versus λ_{res} , matriz de confusão e efeito de incluir as posições Bragg.

II. TRABALHOS RELACIONADOS

A. LPFG, FBG e interrogação

Vengsarkar *et al.* estabeleceram LPFGs como filtros espectrais por acoplamento a modos de revestimento [1]. Kersey *et al.* revisaram sensores a FBG e famílias de interrogadores (filtro sintonizável, interferometria, etc.), consolidando as FBGs como elemento padrão em redes de sensores [2]. Arquiteturas híbridas exploram essa maturidade: um interrogador de FBGs “enxerga” a LPFG indiretamente, via modulação das potências refletidas pelo espectro de transmissão da LPFG.

B. Demodulação LPFG via array FBG e ML

Barino e dos Santos propuseram um interrogador LPG baseado em array FBG e rede neural artificial, mapeando potências em λ_{res} [3]. Em [4], a abordagem foi estendida a um sensor LPFG cascadeado a um array FBG com modelos de aprendizado de máquina. O trabalho subsequente [5] introduz autoatenção, treino sintético e validação experimental, enfatizando filtragem dinâmica dos canais FBG mais relevantes. Em conjunto, essa linha resolve a *regressão* de λ_{res} ; permanece aberta a pergunta de reconhecimento de padrões: como declarar, de forma discreta e avaliável, *quais* FBGs devem entrar na estimação.

A autoatenção em [5] funciona, em essência, como um filtro adaptativo sobre o espectro refletido: canais pouco informativos recebem menor peso. Isso motiva declarar a seleção de canais de forma *explícita* e avaliável — objetivo deste trabalho — em vez de deixá-la apenas implícita nos pesos de uma rede profunda.

C. Classificadores empregados

Comparamos *k*-vizinhos mais próximos (kNN); SVM com kernel RBF [6]; MLP; florestas aleatórias [7]; AdaBoost com árvores de decisão; e um baseline linear (RidgeClassifier, denotado MQ). A escolha privilegia reprodutibilidade e contraste




Figura 1. Esquema: LPFG (Lorentziana ilustrativa), λ_{res} e janela-classe C_s no array de 13 FBGs.

entre indutores lineares e não lineares, em vez de competir diretamente com a arquitetura profunda de [5] na regressão.

III. FORMULAÇÃO DO PROBLEMA

Cada amostra n fornece potências $\mathbf{x}^{(n)} \in \mathbb{R}^{13}$, posições $\lambda_{\text{FBG}}^{(n)} \in \mathbb{R}^{13}$ e o alvo $\lambda_{res}^{(n)}$. O erro $e_i = |\lambda_{\text{FBG},i} - \lambda_{res}|$ induz a máscara top-4 (quatro menores e_i). Fixamos $k = 4$ por coerência com a prática de [5], em que um pequeno subconjunto de canais concentra a informação. No conjunto filtrado, essa máscara é *sempre* contígua; logo o rótulo oficial é

$$y = s \in \{0, \dots, 9\}, \quad C_s = \{s, s+1, s+2, s+3\}. \quad (1)$$

O classificador recebe $\mathbf{x}$ (ou $\mathbf{x}$ concatenado a λ_{FBG} na ablação) e prediz s ; a máscara implícita é C_s . A Fig. 1 resume o esquema físico e a janela-classe em torno de λ_{res} .

A contiguidade não é uma restrição artificial: decorre da ordenação espectral das FBGs ao longo do eixo de comprimento de onda. Janelas vizinhas C_s e C_{s+1} compartilham três índices e diferem por um, o que antecipa confusões adjacentes na matriz de erros.

IV. METODOLOGIA

A. Dados e pré-processamento

Usamos o conjunto medido associado a [5]. No arranjo experimental de referência, LPFG e array de 13 FBGs (centros aproximados entre 1510 e 1590 nm) são cascadeados e lidos por um interrogador comercial de FBGs; a LPFG modula o perfil de refletividade visto pelo interrogador [5]. Há 8200 amostras no arquivo bruto; o filtro $1515 < \lambda_{res} < 1585$ nm — interior ao span do array — produz 7300 exemplos utilizáveis. As potências são normalizadas por amostra (subtração do mínimo e divisão pela soma), como em [5], garantindo invariância a offset e escala global. A Fig. 2 exibe 73 amostras espalhadas ao longo do intervalo de λ_{res} : a faixa de alta potência desloca-se pelas colunas do array, embora λ_{res} não apareça na figura.

A Tabela I quantifica o desbalanceamento. C_2 concentra quase 29% dos exemplos, enquanto C_3 e C_9 ficam abaixo de 1,5%. Esse perfil explica por que F1 macro tende a ficar abaixo de F1 weighted e por que o AdaBoost necessitou de árvores mais profundas e pesos de classe.

Tabela I

DISTRIBUIÇÃO DAS 10 CLASSES NO CONJUNTO FILTRADO ($N = 7300$).

Classe	n	%	Classe	n	%
C_0	520	7,12	C_5	542	7,42
C_1	1257	17,22	C_6	236	3,23
C_2	2089	28,62	C_7	696	9,53
C_3	89	1,22	C_8	270	3,70
C_4	1501	20,56	C_9	100	1,37

B. Classificadores e hiperparâmetros

Comparamos kNN, SVM RBF, MLP, Random Forest, AdaBoost e MQ. kNN, SVM, MLP e MQ usam StandardScaler ajustado apenas no treino de cada partição. As grades de busca incluem, entre outros: $k \in \{3, 5, 7, 11\}$ e pesos uniforme/distância (kNN); $C \in \{0, 1, 10\}$ e $\gamma \in \{\text{scale}, 0, 1\}$ (SVM); arquiteturas e regularização α (MLP); profundidade e número de árvores (RF); e, no AdaBoost, profundidade da árvore base $\in \{2, 3, 4\}$, $n_{\text{estimators}} \in \{100, 200\}$ e taxa de aprendizado $\in \{0, 3, 0, 5, 1, 0\}$, sempre com `class_weight=balanced`. O consenso do AdaBoost no desenvolvimento foi profundidade 4, 200 estimadores e taxa 0,3.

C. Protocolo de avaliação

Reservamos 20% como hold-out estratificado por classe (1460 amostras), intacto até o teste final. No desenvolvimento (5840), usamos StratifiedKFold com 5 folds. A estratificação por y evita folds sem representantes de classes raras, o que seria especialmente problemático para C_3 e C_9 . Hiperparâmetros foram escolhidos por nested CV (GridSearchCV interno, 3 folds, scorer = acurácia), reduzindo viés otimista de ajustar e avaliar na mesma partição [8]. Os modelos de consenso foram retreinados no desenvolvimento completo e avaliados uma única vez no hold-out. Reportamos acurácia e F1 weighted na tabela principal; F1 macro e matrizes de confusão sustentam a discussão de classes raras. Implementações seguem a biblioteca scikit-learn, com semente fixa para reprodutibilidade.

V. RESULTADOS

A. Desempenho agregado

A Tabela II coloca CV e hold-out na mesma visão. SVM lidera a CV ($0,934 \pm 0,004$) e empata com Random Forest no hold-out (0,938). AdaBoost, após o ajuste descrito, entra no pelotão intermediário-alto (0,923 no hold-out), bem acima do baseline linear MQ (0,789), indicando que a fronteira potências $\rightarrow$ janela é essencialmente não linear. O gap entre F1 weighted e F1 macro (omitido da tabela por espaço, porém observado em todos os métodos) acompanha o desbalanceamento da Tabela I.

B. Erros versus λ_{res}

A Fig. 3 mostra a acurácia do SVM por faixas de λ_{res} (predições da CV empilhadas). Faixas centrais do intervalo útil são tipicamente mais fáceis; a degradação concentra-se




Figura 2. Potências FBG normalizadas (73 de 7300 amostras). A diagonal clara indica o deslocamento do padrão pelo array; λ_{res} não é exibido.

Tabela II
DESEMPENHO MULTICLASSE: CV (MÉDIA $\pm$ DESVIO) E HOLD-OUT (HO).

Método	Acc. CV	$F1_w$ CV	Acc. HO	$F1_w$ HO
SVM	0,934 $\pm$ 0,004	0,927	0,938	0,931
RF	0,929 $\pm$ 0,004	0,923	0,938	0,932
AdaBoost	0,924 $\pm$ 0,004	0,923	0,923	0,925
MLP	0,919 $\pm$ 0,011	0,908	0,933	0,923
kNN	0,907 $\pm$ 0,003	0,901	0,919	0,911
MQ	0,779 $\pm$ 0,007	0,736	0,789	0,750

em $\approx 1548\text{--}1580$ nm, região em que classes de janela periféricas e amostras mais escassas se combinam. Essa visão é complementar à Tabela II: o mesmo modelo “médio” esconde heterogeneidade espectral.

C. Matriz de confusão

A Fig. 4 compara as matrizes do SVM e do Random Forest no hold-out, normalizadas por linha. Os erros residuais ocorrem sobretudo entre classes adjacentes — coerente com a sobreposição de três FBGs entre C_s e C_{s+1} . Do ponto de vista da cascata classificação $\rightarrow$ regressão, confundir janelas vizinhas é menos grave do que saltos longos no array, pois o subconjunto de canais permanece parcialmente correto. O pa-




Figura 3. Acurácia do SVM por bin de λ_{res} (CV empilhada).

drão qualitativo semelhante nos dois melhores métodos reforça que o empate em acurácia não é coincidência isolada: ambos capturam a geometria das janelas no espaço de potências. Diferenças pontuais em classes raras são esperadas dada a baixa contagem absoluta (Tabela I).

D. Ablação: posições Bragg

Concatenar λ_{FBG} às potências altera o ranking de forma desigual: MLP (+0,029 em acurácia CV), Random Forest (+0,019) e MQ (+0,041) melhoram; o SVM permanece





Figura 4. Matrizes de confusão no hold-out (% por linha): esquerda, SVM; direita, Random Forest.




Figura 5. Acurácia CV: somente potências versus potências concatenadas às posições Bragg.

quase neutro; o kNN piora ($-0,050$). A Fig. 5 resume essa comparação lado a lado. Interpretamos o prejuízo do kNN como sensibilidade à mudança de escala/dimensionalidade sob distância euclidiana. Para o MQ, as posições adicionam informação linearmente útil que as potências sozinhas não carregam de modo suficiente; para o SVM RBF, as potências já induzem uma margem competitiva sem as coordenadas Bragg.

VI. DISCUSSÃO

Formalizar a seleção de FBGs como dez classes alinha o problema à avaliação clássica de reconhecimento de padrões e torna explícito o conjunto de decisões [8]. Em relação à regressão de [5], o classificador atua como estágio anterior: se C_s for predito corretamente, um estimador de λ_{res} pode operar apenas sobre quatro canais, potencialmente reduzindo ruído de FBGs irrelevantes — hipótese ainda não medida em RMSE.

Do ponto de vista de engenharia de sensores, a cascata classificação→regressão também facilita diagnóstico: falhas de demodulação podem ser atribuídas à janela errada (Fig. 4) ou à estimação contínua dentro da janela correta. Além disso, um classificador raso (SVM/RF) é barato de retreinar quando o array FBG é recalibrado, enquanto o modelo de autoatenção de [5] permanece responsável pela precisão submétrica de λ_{res} .

O desempenho de SVM/RF (0,938 no hold-out) indica que a etapa de janela é tratável com modelos clássicos. Por outro lado, o desbalanceamento (Tabela I) e a otimização por acurácia favorecem classes majoritárias: estratégias futuras incluem scorer macro-F1, reamostragem ou custos assimétricos, sobretudo para C_3 e C_9 . Confusões adjacentes, embora preferíveis a erros longos, ainda podem deslocar a estimação de λ_{res} em frações de nanômetro se a regressão for sensível ao canal excluído/incluído indevidamente.

Limitações: (i) não quantificamos o ganho de RMSE ao fixar a janela antes da regressão; (ii) o protocolo usa um único hold-out (além da CV), suficiente para o escopo da disciplina, porém sensível à partição; (iii) não exploramos modelos profundos na classificação, propositalmente, para isolar o ganho da formulação multiclasse; (iv) a Lorentziana da Fig. 1 é ilustrativa, não um espectro medido.

VII. CONCLUSÃO

Formulamos a seleção das FBGs relevantes à demodulação de LPFG como classificação multiclasse com dez janelas contíguas C_s , explorando a contiguidade observada nos dados filtrados. Com potências normalizadas de um array de 13 FBGs, nested CV e hold-out estratificado, SVM e Random Forest alcançaram acurácia 0,938 no teste final; erros rema-

nescentes concentram-se em classes adjacentes e em faixas de λ_{res} menos povoadas. A ablação com posições Bragg mostra ganhos dependentes do indutor, reforçando que a representação deve ser escolhida junto com o classificador. O trabalho estabelece a Parte 1 de uma arquitetura em cascata cuja Parte 2 — estimacão de λ_{res} restrita à janela predita, na linha de [5] — permanece como próximo passo experimental.

REFERÊNCIAS

- [1] A. M. Vengsarkar, P. J. Lemaire, J. B. Judkins, V. Bhatia, T. Erdogan, and J. E. Sipe, “Long-period fiber gratings as band-rejection filters,” *J. Lightwave Technol.*, vol. 14, no. 1, pp. 58–65, 1996, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/50.476137>
- [2] A. D. Kersey, M. A. Davis, H. J. Patrick, M. LeBlanc, K. P. Koo, C. G. Askins, M. A. Putnam, and E. J. Friebele, “Fiber grating sensors,” *J. Lightwave Technol.*, vol. 15, no. 8, pp. 1442–1463, 1997, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/50.618320>
- [3] F. O. Barino and A. B. dos Santos, “LPG interrogator based on FBG array and artificial neural network,” *IEEE Sensors J.*, vol. 20, no. 23, pp. 14 187–14 194, 2020, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/JSEN.2020.3007957>
- [4] F. O. Barino, V. Pamplona, A. L. M. Marcato, R. M. Capelini, C. C. dos Santos, L. d. M. Honório, C. Duarte, F. Hamaji, and A. B. dos Santos, “Demodulation of an LPFG sensor cascaded by an FBG sensor array using machine learning,” in *Proc. Latin Amer. Workshop Opt. Fiber Sensors (LAWOFS)*, 2024, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.23919/LAWOFS62242.2024.10560772>
- [5] F. O. Barino and A. B. dos Santos, “Self-attention AI model for practical sensor networking: Demodulation of long-period fiber grating sensor cascaded with FBG sensor array,” *IEEE Trans. Instrum. Meas.*, vol. 74, pp. 1–10, 2025, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1109/TIM.2025.3573014>
- [6] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1007/BF00994018>
- [7] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1023/A:1010933404324>
- [8] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009, acessado em: 17 de julho de 2026. [Online]. Available: <https://doi.org/10.1007/978-0-387-84858-7>