

Classificação multiclasse de janelas de FBGs para demodulação de LPFG

Trabalho Final — Reconhecimento de Padrões

Jakson da Rocha Almeida

Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Juiz de Fora (UFJF)

- 1 Motivação e problema
- 2 Dados e pré-processamento
- 3 Metodologia
- 4 Resultados
- 5 Conclusões

- Sensores LPFG exigem, em geral, interrogação espectral cara.
- Alternativa: array de FBGs + aprendizado de máquina para estimar λ_{res} .
- No trabalho do Barino, a atenção sugere que **nem todas as FBGs importam igualmente**.

Pergunta de RP:

a partir das potências das 13 FBGs, *qual janela* de 4 FBGs contíguas é a relevante?

Objetivo deste trabalho

Parte 1 — Classificação (foco)

Predizer a **classe** $s \in \{0, \dots, 9\}$ correspondente à janela $C_s = \{s, s + 1, s + 2, s + 3\}$ (4 FBGs contíguas).

Parte 2 — Interrogação (contexto)

Estimar λ_{res} (já feita no paper do Barino; não refeita aqui).

Entregas: artigo IEEEtran + apresentação (15 min).

Formulação multiclasse (10 classes)


Entrada $x \in \mathbb{R}^{13}$

potências ópticas normalizadas.

Rótulo $y = s \in \{0, \dots, 9\}$

máscara top-4 por $|\lambda_{\text{FBG}} - \lambda_{\text{res}}|$
 $\Rightarrow$ sempre janela contígua nos dados.

Predição: $\hat{s} = \arg \max$ da classe
(máscara implícita = $C_{\hat{s}}$).



- Fonte: `measured.dataset` (dados **reais**, autorizados).
- Bruto: 8200 $\rightarrow$ filtrado ($1515 < \lambda_{res} < 1585$): **7300**.
- Normalização: $X \leftarrow X - \min(X)$; $X \leftarrow X / \sum X$.
- **10 classes** presentes; desbalanceadas (ex.: $C_2 \approx 29\%$, $C_3 \approx 1,2\%$).

- Filtro de faixa alinhado ao Barino.
- Rótulo: janela top-4 $\rightarrow$ classe $C_0, \dots, C_9$.
- Observação: máscara 100% contígua $\Rightarrow$ multiclasse é natural.

- Hold-out estratificado por **classe** (20%): 1460 amostras.
- CV: StratifiedKFold 5 folds no desenvolvimento (5840).
- Nested CV para hiperparâmetros (scorer = **acurácia**).
- Hold-out avaliado *uma vez* após o tuning.

Seis métodos da disciplina (multiclasse nativo):

- kNN (+ scaler)
- SVM RBF
- MLP (+ scaler)
- Random Forest
- AdaBoost
- MQ / RidgeClassifier

Métricas: acurácia, F1 weighted/macro, matriz 10×10 .

- Consenso estável do SVM: $C=10$, $\gamma=0,1$ (todos os folds).
- Maior ganho do tuning: SVM acurácia $0,905 \rightarrow 0,934 (+0,029)$.

Resultados — CV (modelos afinados)

Método	Acurácia	F1 weight.	F1 macro
SVM	$0,934 \pm 0,004$	0,927	0,866
Random Forest	$0,929 \pm 0,003$	0,923	0,857
MLP	$0,919 \pm 0,010$	0,908	0,819
kNN	$0,907 \pm 0,003$	0,901	0,830
MQ	$0,779 \pm 0,006$	0,736	0,580
AdaBoost	$0,650 \pm 0,010$	0,554	0,365



Resultados — hold-out

Método	Acurácia	F1 weight.	F1 macro
SVM	0,938	0,931	0,874
Random Forest	0,938	0,932	0,878
MLP	0,933	0,923	0,846
kNN	0,919	0,911	0,824
MQ	0,789	0,750	0,613
AdaBoost	0,543	0,409	0,209

Ranking estável: **SVM** e **RF** lideram no hold-out.


Exemplo: janela verdadeira vs prevista

Janela verdadeira (▼) vs SVM (▲)









Análise: erros vs λ_{res}

- Pior faixa do SVM: $\approx 1548\text{--}1580$ nm (acurácia $\approx 0,87$).
- Faixa 1531–1534 nm: acurácia $\approx 0,996$.



Matrizes de confusão 10×10

Matrizes 10×10 (%) — hold-out
percentual por linha



Ablation: + posições Bragg

- Melhora MLP/RF/MQ; quase neutro no SVM; **piora** o kNN ($-0,05$).

- Problema de RP bem posto: **10 classes** de janelas contíguas.
- Métricas alinhadas à disciplina: acurácia + matriz de confusão.
- Melhores métodos: **SVM** e **Random Forest** (acurácia $\approx 0,938$ no hold-out).
- Classes raras e AdaBoost fraco são limitações claras.
- Próximo passo: acoplar a janela à regressão de λ_{res} .

Agradecimento ao Dr. Felipe Oliveira Barino
pela autorização de uso dos dados e código.

Obrigado.

Perguntas?