

Classificação multi-rótulo de FBGs relevantes para demodulação de LPFG

Trabalho Final — Reconhecimento de Padrões

Jakson da Rocha Almeida

Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Juiz de Fora (UFJF)

- 1 Motivação e problema
- 2 Dados e pré-processamento
- 3 Metodologia experimental
- 4 Resultados
- 5 Conclusão

- Sensores LPFG exigem, em geral, interrogação espectral cara.
- Alternativa: array de FBGs + aprendizado de máquina para estimar λ_{res} .
- No trabalho do Barino, a atenção sugere que **nem todas as FBGs importam igualmente**.

Pergunta de reconhecimento de padrões:

a partir das potências das 13 FBGs, *quais* são as relevantes para localizar o vale?

Objetivo deste trabalho

Parte 1 — Classificação (foco)

Predizer uma **máscara multi-rótulo** $y \in \{0, 1\}^{13}$:
os k FBGs mais próximos de λ_{res} ($k=4$).

Parte 2 — Interrogação (contexto)

Estimar λ_{res} (já feita no paper do Barino; não refeita aqui).

Entregas da disciplina: artigo IEEEtran + apresentação (15 min).

Formulação do problema de RP

Entrada $x \in \mathbb{R}^{13}$


potências ópticas normalizadas.

Rótulo $y \in \{0, 1\}^{13}$

$$e_i = |\lambda_{\text{FBG},i} - \lambda_{\text{res}}|$$

$y_i = 1$ nos k menores e_i .

Predição: top- k nos escores
(cardinalidade fixa = 4).



- Fonte: `measured.dataset` (dados **reais**, autorizados).
- Contexto: demodulação LPFG com array FBG (Barino et al.).
- Cada amostra corresponde a uma configuração medida do sistema óptico.

Campo	Dimensão	Uso em RP
<code>input_strength</code>	13	atributos (X)
<code>wl_bragg</code>	13	gera rótulo
<code>target</code> (λ_{res})	1	gera rótulo

- 1 **Filtro de faixa:** manter $1515 < \lambda_{res} < 1585$ nm
8200 $\rightarrow$ 7300 amostras (900 removidas).
- 2 **Normalização** (por amostra, critério do Barino):
 $X \leftarrow X - \min(X); \quad X \leftarrow X / \sum X.$
- 3 **Rótulo top-4** a partir de $|\lambda_{FBG} - \lambda_{res}|.$

Observação

A máscara é **desbalanceada** por canal:
FBG 4 $\approx$ 68% positivos; FBG 12 $\approx$ 1,4%.

Atributos e rótulos (visão de RP)

- **Atributos:** 13 potências normalizadas (protocolo principal).
- **Rótulo:** vetor binário 13D (multi-rótulo), exatamente 4 uns.
- **Ablação:** também testamos concatenar λ_{FBG} à entrada.
- Há 10 padrões de máscara distintos no conjunto filtrado.

Coerência espacial do rótulo: correlação posição FBG $\times \lambda_{\text{res}}$
quando o canal é positivo $\approx 0,992$.

- Semente fixa: `random_state=42`.
- Hold-out estratificado (20%): **1460** amostras — só relatório final.
- Desenvolvimento: **5840** amostras.
- CV: `StratifiedKFold` (5 folds) por quantis de λ_{res} .
- Em cada fold da CV: treino 4672 / teste 1168.
- Nested CV para hiperparâmetros (scorer = Jaccard top- k).
- Sem SMOTE; hold-out nunca usado no ajuste.

Seis métodos da disciplina, adaptados a multi-rótulo:

- kNN (+ scaler)
- SVM RBF one-vs-rest
- MLP (+ scaler)
- Random Forest
- AdaBoost one-vs-rest
- MQ / Ridge + top- k

Métricas: Jaccard (principal), exact match, F1 micro/macro, Hamming.


Predição alinhada ao problema: **top-4 por score**.

Ajuste de hiperparâmetros (resumo)

- Nested CV no desenvolvimento (busca só no treino de cada fold).
- Consenso estável do SVM: $C=10$, $\gamma=0,1$ (todos os folds).
- Maior ganho do tuning: SVM Jaccard $0,961 \rightarrow 0,974$ (+0,013).
- Demais métodos: variação pequena após o ajuste.

Resultados — CV (modelos afinados)

Método	Jaccard	Exact	F1 mic.	Hamm.
SVM	0,974 ± 0,003	0,935	0,984	0,010
Random Forest	0,973 ± 0,002	0,933	0,983	0,010
AdaBoost	0,973 ± 0,004	0,932	0,983	0,011
MLP	0,965 ± 0,006	0,912	0,978	0,014
kNN	0,964 ± 0,002	0,910	0,978	0,014
MQ	0,922 ± 0,005	0,805	0,951	0,030



Resultados — hold-out (avaliação única)


Treino no desenvolvimento completo; teste no hold-out (1460):

Método	Jaccard	Exact	F1 micro
SVM	0,975	0,938	0,985
Random Forest	0,974	0,936	0,984
MLP	0,974	0,934	0,984
AdaBoost	0,973	0,934	0,983
kNN	0,967	0,918	0,979
MQ	0,933	0,832	0,958

Ranking estável: **SVM** lidera também no hold-out.


Exemplo: máscara verdadeira vs prevista

Máscara top-4: verdadeira (▼) vs SVM (▲)




Análises adicionais

- **Erros vs λ_{res}** : o pior bin não é a borda ($\sim 1553\text{--}1564$ nm, Jaccard $\approx 0,91$).
- $k \in \{3, 4, 5\}$: SVM lidera; $k=3$ é mais fácil; mantemos $k=4$.
- + **posições FBG**: ajuda RF/MLP/AdaBoost/MQ; SVM quase neutro; kNN **piora** ($-0,022$).



Erro por canal (FBG)



Canais raros (bordas do array) tendem a maior taxa de erro — coerente com o desbalanceamento do rótulo.

- Problema de RP bem posto: multi-rótulo top-4 sobre 13 potências.
- Dados reais (7300 amostras úteis), CV + hold-out isolado.
- Melhor método: **SVM RBF one-vs-rest** (Jaccard $\approx 0,975$ no hold-out).
- MQ serve como baseline linear mais fraco.
- Próximo passo natural: acoplar a máscara à regressão de λ_{res} .

Obrigado.

Agradecimento ao Dr. Felipe Oliveira Barino
pela autorização de uso dos dados.

Perguntas?